



Universidade Federal do Amazonas
Instituto de Ciências Exatas e Tecnologia
Projeto para Educação e Pesquisa



RELATÓRIO TÉCNICO CIENTÍFICO 1:

Um Mapeamento Sistemático sobre as Contribuições do Machine Learning: Áreas, Aplicações e Algoritmos

Alunos:

Lucas de Souza Pinheiro
lucas.pinheiro@ufam.edu.br

Maryse da Silva Pires
marysepires12@ufam.edu.br

Orientadora:

Prof. Dra. Odette Mestrinho Passos

Itacoatiara - AM

2024

Sumário

| | |
|---|----|
| 1. INTRODUÇÃO | 3 |
| 2.1. Inteligência Artificial | 4 |
| 2.2. Machine Learning | 4 |
| 3. METODOLOGIA | 5 |
| 4. PLANEJAMENTO DO MS | 6 |
| 4.1. Objetivo e Questões de Pesquisa | 7 |
| 4.2. Fontes, Idioma e Expressão de Busca..... | 7 |
| 4.3. Critérios de Seleção | 7 |
| 4.4. Extração dos Dados | 8 |
| 5. CONDUÇÃO DO MS | 8 |
| 6. RESULTADOS DO MS | 10 |
| 7. CONSIDERAÇÕES FINAIS | 24 |
| REFERÊNCIAS | 26 |
| APÊNDICE A..... | 29 |

1. INTRODUÇÃO

O Aprendizado de Máquina (ML – do inglês *Machine Learning*) é um campo da inteligência artificial que utiliza algoritmos para coletar e analisar dados, aprender com eles e fazer previsões ou determinação, surgindo da necessidade de lidar com grandes volumes de dados e extrair informações valiosas a partir deles (Mitchell, 1997). O uso do ML está se tornando cada vez mais presente no Brasil, com empresas adotando soluções de ML para melhorar a eficiência operacional, prever tendências de mercado e personalizar experiências de clientes (Rubí, Carvalho e Gondim, 2023). No âmbito da saúde, suas aplicações não são menos impressionantes, previsões precisas e personalizadas estão moldando as estratégias de prevenção e tratamento, ampliando as fronteiras do diagnóstico e da assistência médica (Oliveira, 2017). Além disso, há um número crescente de profissionais e acadêmicos envolvidos em pesquisas e aplicações de ML no Brasil, destacando o impacto positivo que essa tecnologia pode ter na economia e na sociedade (Dias, 2021).

Ao redor do mundo, ele tem desempenhado um papel transformador em diversos setores (Szczepanki, 2019). Estudos revelam que o ML tem tido sucesso na análise de fatores socioeconômicos e estruturais que influenciam o impacto de doenças como a COVID-19 (Rodas, 2022). O advento da Inteligência Artificial (IA), do Big Data e do aprendizado de máquina tem impulsionado a rápida expansão do uso dessas ferramentas no dia a dia, moldando economias e sociedades em todo o mundo, além de impulsionar inovações e avanços em áreas como saúde, biomedicina, manufatura, educação, modelagem financeira, governança de dados, policiamento e marketing (Santos, 2019).

Neste contexto, a presente pesquisa visa coletar informações sobre o atual cenário de ML em simpósios brasileiros. O objetivo é identificar as áreas que atualmente empregam essa tecnologia, destacando suas aplicações mais relevantes e os algoritmos mais prevalentes. Para identificar os artigos sobre a temática deste trabalho, foi realizado um Mapeamento Sistemático (MS) que visa fornecer uma visão geral de uma área de pesquisa, identificando a quantidade, os tipos de pesquisas realizadas, os resultados disponíveis, além das frequências de publicações ao longo do tempo para identificar tendências (Petersen *et al.*, 2008).

Os resultados revelam que a ML é utilizada em 16 áreas distintas, onde notou-se que a área com mais contribuição da ML foi a da Computação. Dentro das áreas identificadas, houve um total de 147 aplicações que apesar de se mostrarem diferentes na abordagem, mostram semelhanças nos resultados positivos nos processos aplicados. Nesse contexto, foram apresentados 62 tipos de algoritmos, destacando o Random Forest como o mais utilizado dentre os estudos selecionados, mostrando ser eficaz em todas as áreas identificadas e em uma variedade de aplicações com diferentes finalidades.

A pesquisa foi conduzida pelos alunos que participam do projeto SUPER, no âmbito do Instituto de Ciências Exatas e Tecnologia, que visa estimular a capacitação e a pesquisa em cursos de graduação da Universidade Federal do Amazonas (UFAM).

O restante do relatório segue organizado da seguinte forma: A Seção 2 explora os conceitos relacionados, enquanto a Seção 3 descreve a metodologia adotada, bem como o planejamento do MS. A Seção 4 discute a execução do MS e a Seção 5 apresenta os resultados e as discussões. A Seção 6 apresenta as considerações finais, limitações do trabalho e trabalhos futuros.

2. CONCEITOS RELACIONADOS

2.1. Inteligência Artificial

A IA abrange um domínio de conhecimento relacionado à linguagem, inteligência, raciocínio, aprendizado e resolução de problemas (Kaufman, 2019). O matemático Alan Turing é reconhecido como um dos pioneiros nessa área. Em 1950, ele publicou um artigo no qual se propôs a examinar a capacidade das máquinas de pensar. Utilizando jogos de adivinhação como base, Turing explorou a viabilidade dessas ideias nos computadores digitais emergentes na época. Ele analisou vários argumentos sobre a natureza do pensamento, assim como sobre o funcionamento dos neurônios, para determinar se as máquinas poderiam adquirir conhecimento de maneira semelhante aos seres humanos (Turing, 1950).

Conforme Fernandes (2003), a origem da expressão "inteligência artificial" deriva do latim, dividindo-se em "inter" (entre) e "legere" (escolher). Portanto, a inteligência é definida como a capacidade humana de fazer escolhas entre diferentes opções, sendo esse o modo de resolver problemas e realizar tarefas. Os princípios essenciais da Inteligência Artificial abrangem algoritmos de aprendizado de máquina, redes neurais artificiais, processamento de linguagem natural, visão computacional, entre outros. Essas abordagens são empregadas para instruir os sistemas de IA sobre como executar tarefas específicas (Goodfellow, Bengio e Courville, 2016).

Entre os exemplos mais notáveis do emprego de IA, destaca-se a capacidade de interação na linguagem humana, exemplificada pelos assistentes pessoais em nossos celulares, e a habilidade de perceber e interpretar o mundo, como evidenciado no reconhecimento de imagens por carros autônomos (Garcia, 2020). A utilização da IA tem proporcionado uma série de benefícios, tais como melhorias nos serviços de saúde, processamento de linguagem natural, avanços na educação, energia limpa e acessível, detecção de fraudes, e a promoção de meios de transporte mais seguros, eficientes e ecologicamente sustentáveis (Ludermir, 2021).

2.2. Machine Learning

Da mesma forma, em vez de codificar o conhecimento em computadores, a ML busca aprender automaticamente relações e padrões significativos a partir de exemplos e observações (Bishop 2006). O objetivo da ML é a construção de programas que melhorem seu desempenho por meio de exemplos (Mitchell, 1997). Algumas áreas da ML estão estreitamente relacionadas à mineração de dados e à estatística, a pesquisa nesse domínio concentra-se nas características dos métodos estatísticos, bem como em sua complexidade computacional (Amorim, Barone e Mansur, 2008).

A ML possui destaque em cenários onde: (1) a solução do problema exige grande esforço de ajustes manuais ou ainda diversas derivações de regras, (2) as abordagens

tradicionais, que não utilizam arcabouços estatísticos e probabilísticos, não propiciam uma solução ótima para o problema, (3) os ambientes são dinâmicos, isto é, os dados sofrem mudanças frequentes (por exemplo, preços de ações) e (4) é necessário a geração de conhecimento a partir de grande quantidade de dados (Géron, 2017).

Os algoritmos de ML podem ser categorizados em supervisionados, não supervisionados, semi-supervisionados e aqueles que adotam a aprendizagem por reforço. Os algoritmos supervisionados requerem dados de treino com rótulos prévios, ao passo que os não supervisionados utilizam dados de treino sem rótulos previamente atribuídos. Os algoritmos semi-supervisionados têm a capacidade de lidar com conjuntos de treino parcialmente rotulados. Já os algoritmos de aprendizagem por reforço executam ações com base no feedback obtido por meio de interações com o ambiente, visando criar soluções (modelos) generalizáveis (Gerón, 2017).

3. METODOLOGIA

Foi realizado um MS, para coletar as informações necessárias a fim de cumprir o objetivo do trabalho, que se baseia nas diretrizes desenvolvidas por Kitchenham e Charters (2007). De acordo com eles, o processo do MS consiste em três etapas definidas, conforme mostra a Figura 1:

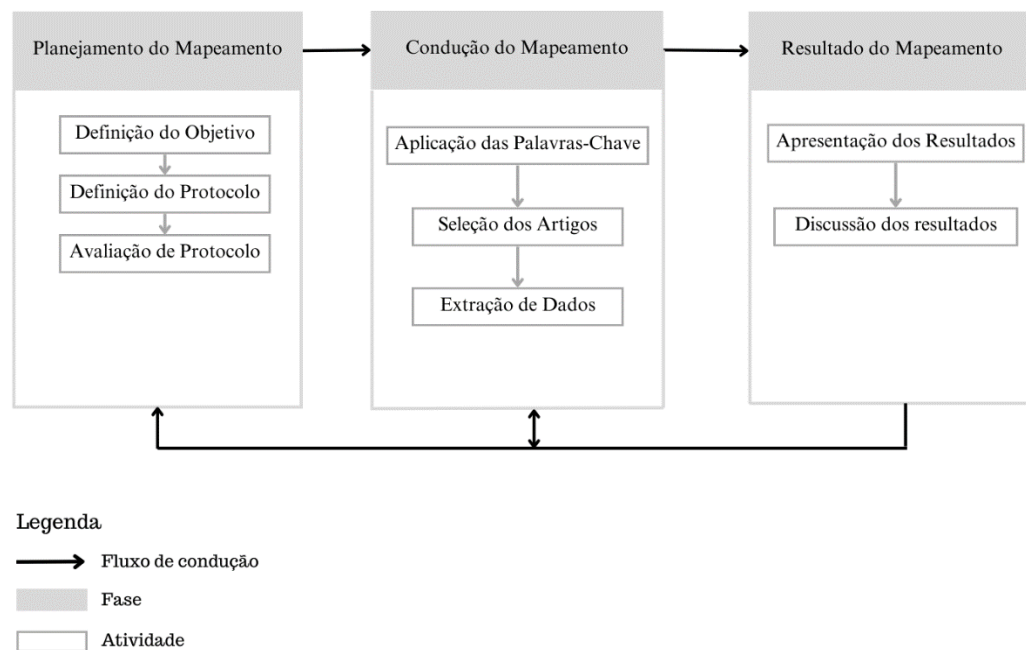


Figura 1 - Etapas e Atividade do Mapeamento Sistemático

Fonte: Adaptado de Kitchenham e Charters (2007)

- **Planejamento do Mapeamento:** Nessa etapa, são listados os objetivos da pesquisa e o protocolo do mapeamento é estabelecido. Elabora-se um protocolo detalhado que inclui critérios de inclusão e exclusão, estratégias de busca, fontes de informação a serem consultadas e procedimentos para seleção e avaliação dos dados. É essencial realizar uma revisão completa da literatura existente sobre o tema para evitar duplicação de esforços e garantir a relevância da pesquisa.

- **Condução do Mapeamento:** Durante essa fase, são selecionadas as fontes para o mapeamento, os estudos relevantes são identificados, selecionados e avaliados de acordo com os critérios estabelecidos no protocolo do mapeamento.
- **Resultado do Mapeamento:** Nessa etapa, os dados dos estudos são extraídos e sintetizados para posterior publicação. É realizada uma discussão dos resultados, incluindo suas implicações e limitações, e são identificadas possíveis direções futuras para pesquisas adicionais.

O protocolo, definido na primeira etapa, busca construir um esquema que direciona as pesquisas, de modo que o objetivo da pesquisa seja alcançado e apresentado em forma de documento. Todavia, antes de definir o protocolo de um MS, é necessário determinar o objeto a ser pesquisado, ou seja, o escopo da pesquisa que se deseja obter informações relevantes que estejam disponíveis na literatura da área de conhecimento escolhida para o estudo. A partir disso, devem-se definir as questões de pesquisa, as fontes onde as publicações devem ser pesquisadas, a expressão de busca, os critérios de seleção e a extração dos dados que se deseja identificar, que compõem o protocolo. Para Kitchenham e Charter (2007) e Petersen *et al.*, (2008), a estrutura das questões de pesquisa pode ser definida a partir da elaboração de mecanismos de tratamento, como: população (*population*), intervenção (*intervention*) e resultados (*outcomes*). A população é caracterizada pela grande área que se está sendo pesquisada, em contrapartida a intervenção são os tópicos específicos que são alternativos de comparação. A população é afetada pela intervenção.

O processo para realizar as buscas nas fontes determinadas pode ser dividido em automático e/ou manual (Silva, 2012). A busca manual permite definir as principais conferências da área que foi escolhida, e a partir disso identificar manualmente através das palavras-chaves definidas nas publicações relevantes que estejam relacionados com o escopo da pesquisa. Diferentemente das buscas manuais, as buscas automáticas realizadas nas máquinas de busca são capazes de indexar e localizar conteúdo armazenado em sistemas computacionais de forma automatizada (Silva, 2012).

4. PLANEJAMENTO DO MS

No Planejamento do MS, primeiramente, foi realizada uma Revisão Inicial (RI), para obter subsídios de forma a compor o protocolo de pesquisa do MS. Para isso foi visto na plataforma SBC OpenLib (SOL) artigos referentes a ML, nos seguintes evento: Congresso Brasileiro de Informática na Educação (CBIE), Simpósio Brasileiro de Robótica e Simpósio Latino Americano de Robótica (SBR/LARS), Simpósio Brasileiro de Engenharia de Sistemas Computacionais (SBESC), Simpósio Brasileiro de Segurança da Informação (SBSeg) e de Sistema Computacionais (SBSEG), Congresso sobre Tecnologias na Educação (CTRL+E), Simpósio Brasileiro de Computação Ubíqua e Pervasiva (SBCUP), Simpósio Brasileiro de Sistemas de Informação (SBSI), Simpósio Brasileiro de Engenharia de Software (SBES), Simpósio Brasileiro de Banco de Dados (SBBD), Encontro Nacional de Inteligência Artificial e Computacional (ENIAC). Posteriormente, depois de ter verificado as publicações em cada evento, foram selecionados os mais pertinentes para a pesquisa, isto é, aqueles que continham mais publicações sobre a área em questão.

4.1. Objetivo e Questões de Pesquisa

O objetivo deste MS é identificar e analisar a contribuição da ML no contexto brasileiro por meio da análise de simpósios realizados no país. Sendo assim, este MS irá buscar respostas para as seguintes questões de pesquisa:

- **Primeira Questão de Pesquisa (QP1):** Quais as áreas a ML está sendo utilizada?
- **Segunda Questão de Pesquisa (QP2):** Quais aplicações mais relevantes dentro de cada área?
- **Terceira Questão de Pesquisa (QP3):** Quais são os principais algoritmos utilizados?

4.2. Fontes, Idioma e Expressão de Busca

Os locais de buscas para a obtenção de publicações relevantes, a partir da busca manual, serão os anais das conferências nacionais apoiadas pela SBC (Sociedade Brasileira de Computação): SBR/LARS, SBESC, SBSEG, SBCUP, SBES, ENIAC e SBBD. A Tabela 1 apresenta o número de edições de cada evento.

Tabela 1 – Eventos x Edições

| Anais do Eventos | Edições |
|--|---------|
| Simpósio Brasileiro de Engenharia de Software (SBES) | 37 |
| Simpósio Brasileiro de Robótica e Simpósio Latino Americano de Robótica (SBR/LARS) | 10 |
| Simpósio Brasileiro de Engenharia de Sistemas Computacionais (SBESC) | 11 |
| Simpósio Brasileiro de Sistemas de Informação (SBSI) | 19 |
| Simpósio Brasileiro de Computação Ubíqua e Pervasiva (SBCUP) | 14 |
| Simpósio Brasileiro de Segurança da Informação e de Sistema Computacionais (SBSEG) | 23 |
| Encontro Nacional de Inteligência Artificial e Computacional (ENIAC) | 10 |

Fonte: Os Autores (2023)

Os idiomas escolhidos foram o Inglês (devido à sua adoção pela maioria das conferências, periódicos e editoras da área de pesquisa) e o Português (para incluir trabalhos técnicos publicados em conferências nacionais). Para a investigação foram utilizadas as seguintes palavras-chave: “Machine Learning” OR “Deep Learning” OR “Deep Reinforcement Learning” OR “Reinforcement Learning”. Visto que a busca foi realizada manualmente, não foi composta uma expressão de busca específica.

4.3. Critérios de Seleção

A busca por materiais de análise se restringiu a publicações que estivessem disponíveis na internet de forma gratuita, entre os anos de 2018 e 2022. A seleção das publicações foi realizada em três fases: (i) Busca inicial por publicações nas fontes definidas, (ii) Primeiro Filtro de Seleção: por meio da análise do título, resumo e palavras-chaves que continham as palavras-chaves e (iii) Segundo Filtro de Seleção: por meio da leitura na íntegra das publicações e que continham, pelo menos, a resposta de uma das QP.

4.4. Extração dos Dados

Das publicações relevantes para a pesquisa serão extraídas algumas informações que serão registradas em tabelas, de acordo com os campos abaixo mostrados na Tabela 2:

Tabela 2 - Modelo da Tabela de Extração de Dados

| ID da Publicação: | |
|--------------------------------|---|
| A) Dados da Publicação | |
| Título | Indica o título do trabalho |
| Autor(es) | Indica o(s) nome(s) do(s) autor(es) do trabalho |
| Fonte de Publicação | Local de publicação |
| Ano da Publicação | Ano de publicação |
| Resumo | Resumo do trabalho |
| B) Dados Derivados do Objetivo | |
| Área | Indicação da área que está sendo aplicada a ML |
| Aplicação | Indicação de que forma está sendo aplicada a ML |
| Algoritmos | Indicação dos algoritmos de ML mais utilizados |
| C) Dados Adicionais | |
| Outros | Outras informações consideradas importantes |

Fonte: Os Autores (2023)

5. CONDUÇÃO DO MS

Após a fase de planejamento, a busca manual foi executada nas fontes definidas e as publicações foram selecionadas de acordo com os critérios de seleção preestabelecidos durante o protocolo do MS. Foram descartadas publicações duplicadas, inacessíveis ou indisponíveis na Internet, além dessas também foram descartadas publicações que claramente não abordavam assuntos que tinham a ver com o tema desta pesquisa.

Foram investigados, por buscas manuais, anais do SBES, obtendo 8 publicações, da (SBR/LARS), obtendo 27 publicações, anais do (SBESC), obtendo 15 publicações, anais do (SBSI), obtendo 20 publicações, anais do (SBCUP), obtendo 5 publicações, anais do (SBSEG), obtendo 12 publicações, anais do (ENIAC), obtendo 72 publicações, todas do ano de 2018 até o ano de 2022, obtendo um total de 147 publicações. A Tabela 3 apresenta o total de publicações retornadas.

Do total de publicações que resultaram no 1º Filtro, todas foram lidas na íntegra e 147 foram selecionadas por estarem de acordo com os critérios de seleção. Para todas essas publicações foram preenchidas as informações na Tabela 2, conforme a definição descrita no planejamento do MS para a extração de dados. No Apêndice (Tabela A1), pode ser observado as publicações selecionadas após o 2º Filtro de acordo com o seu ano de publicação. Será referenciado neste artigo o ID dessas publicações, conforme descrito na Tabela A1 citada acima. A Figura 2 mostra a quantidade de publicações por ano e a Figura 3 mostra a quantidade por evento.

Tabela 3 - Quantidade de publicações selecionadas

| Fonte | Inicialmente | 1º Filtro | 2º Filtro |
|--|--------------|-----------|-----------|
| Simpósio Brasileiro de Engenharia de Software (SBES) | 258 | 11 | 10 |
| Simpósio Brasileiro de Robótica e Simpósio Latino Americano de Robótica (SBR/LARS) | 295 | 16 | 16 |
| Simpósio Brasileiro de Engenharia de Sistemas Computacionais (SBESC) | 139 | 16 | 15 |
| Simpósio Brasileiro de Sistemas de Informação (SBSI) | 301 | 32 | 18 |
| Simpósio Brasileiro de Computação Ubíqua e Pervasiva (SBCUP) | 106 | 4 | 4 |
| Simpósio Brasileiro de Segurança da Informação e de Sistema Computacionais (SBSEG) | 181 | 14 | 12 |
| Encontro Nacional de Inteligência Artificial e Computacional (ENIAC) | 384 | 83 | 72 |
| Total | 1.649 | 176 | 147 |

Fonte: Os Autores (2023)




Figura 2 - Quantidade de publicações por ano

Fonte: Os Autores (2023)




Figura 3 - Quantidade de publicações por evento

Fonte: Os Autores (2023)

6. RESULTADOS DO MS

Com as informações obtidas nas 147 publicações selecionadas, foi possível responder às questões de pesquisa definidas no protocolo. Todas as publicações foram analisadas de forma manual preenchendo as lacunas sugeridas.

Com relação à **QP1 “Quais as áreas a ML está sendo mais utilizada?”**, foram identificadas 19 grandes áreas conforme observado na Tabela 4. Dentro dessas 19 áreas, 5 áreas tiveram maior destaque, pois apresentaram mais de 10 citações representadas na Figura 4.

Tabela 4 – Áreas identificadas nos artigos

| ID | Área | Artigos | Quantitativo |
|-----|----------------------------|--|--------------|
| A1 | Computação | [P05], [P14], [P16], [P28], [P34], [P53], [P55], [P60], [P66], [P68], [P71], [P79], [P81], [P83], [P141], [P06], [P103], [P107], [P108], [P109], [P110], [P111], [P112], [P113], [P114], [P115], [P116], [P130], [P134], [P135], [P137] e [P142] | 32 |
| A2 | Robótica | [P117], [P118], [P119], [P120], [P121], [P122], [P123], [P124], [P125], [P127], [P128], [P129], [P131] e [P132] | 14 |
| A3 | Saúde | [P19], [P22], [P23], [P24], [P25], [P35], [P39], [P54], [P59], [P67], [P76], [P95], [P99] e [P102] | 14 |
| A4 | Segurança | [P13], [P75], [P77], [P80], [P82], [P84], [P85], [P86], [P87], [P88], [P94], [P10] e [P104] | 13 |
| A5 | Agricultura | [P08], [P11], [P26], [P27], [P40], [P42], [P64], [P70], [P100], [P126] e [P139] | 11 |
| A6 | Ciências Sociais e Humanas | [P02], [P17], [P36], [P41], [P44], [P47], [P57], [P91] e [P97] | 9 |
| A7 | Economia | [P09], [P31], [P32], [P49], [P50], [P58], [P69], [P90], [P106] | 9 |
| A8 | Direito e Justiça | [P01], [P15], [P20], [P30], [P33], [P38], [P51] e [P74] | 8 |
| A9 | Mídia e Entretenimento | [P12], [P37], [P48], [P52], [P61], [P93] e [P105] | 7 |
| A10 | Industrial | [P03], [P04], [P10], [P13], [P56], [P136] e [P147] | 7 |
| A11 | Mobilidade Urbana | [P46], [P62], [P73], [P78], [P138] e [P146] | 6 |
| A12 | Gestão Pública | [P29], [P43], [P92], [P96] e [P98] | 5 |
| A13 | Ciências Naturais | [P63], [P65], [P72], [P89] e [P144] | 5 |
| A14 | Meio Ambiente | [P21], [P133] e [P140] | 3 |
| A15 | Engenharia Elétrica | [P143] e [145] | 2 |
| A16 | Aeronáutica | [P07] e [P45] | 2 |

Fonte: Os Autores (2023)

A área que obteve a maior quantidade de citações, que equivale a 32 publicações, foi a área da Computação. Esta área dedica-se ao estudo de dispositivos, ferramentas tecnológicas e metodologias computacionais. Seu foco está na informatização e automação de processos, visando criar soluções tecnológicas através do processamento de dado que se refere a ciência exata que estuda dispositivos, ferramentas tecnológicas e metodologias computacionais, que informatizam ou automatizam processos, de modo que se criem soluções tecnológicas por meio de processamento de dados (Roveda, 2023).

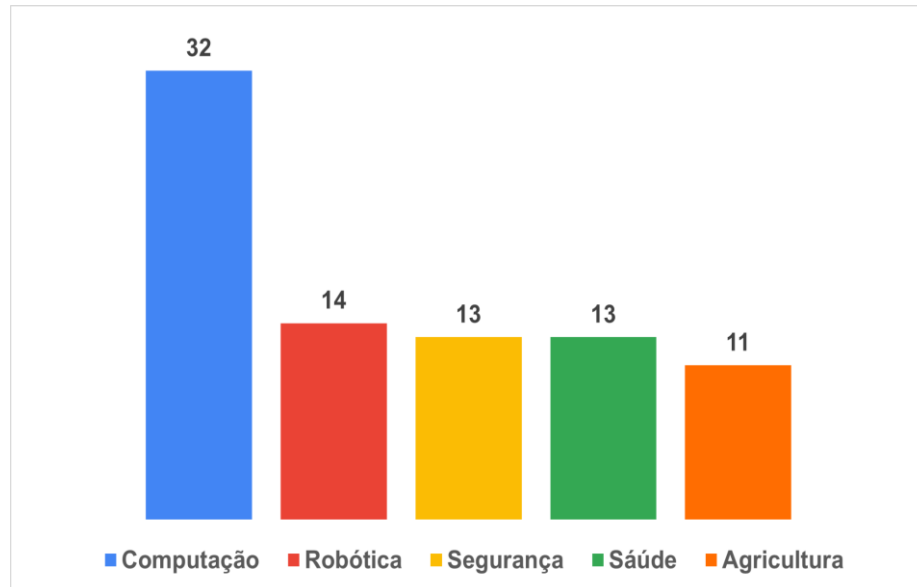


Figura 4 - As 5 áreas com mais de 10 citações

Fonte: Os Autores (2023)

Na área da Computação podemos citar a subárea Engenharia de Software (ES) que obteve 12 citações, que foca na implementação de uma abordagem sistemática, disciplinada e mensurável no desenvolvimento, operação e manutenção de software (Pressman, 2006). Nessa subárea os algoritmos foram utilizados para otimizar processos de testes de software ([P10] e [P111]) e verificar com maior precisão códigos que necessitavam de manutenção ([P107] e [P112]). Na subárea Ciência da Computação, foram citados a mineração de dados [P28], classificação de dados [P55] e otimização de processos [P137].

Já na subárea Tecnologia da Informação (TI), houve contribuição na criação de um modelo determinístico, para monitoramento de desempenho de turbinas, manutenção e previsão de potência [P141], assim como detecção de invasões e ataques em dispositivos de Internet das Coisas (IoT) [P81] e [P8]. A subárea IA, destacou estudos voltados à análise de identificação de fala [P16], reconhecimento de expressões faciais [P66], bem como projetos para otimizar outros tipos de modelos de ML [P60].

A área de Robótica foi citada em 14 artigos, sendo esta ampla e com muitos campos abrangentes. A Robótica é o estudo dos robôs e de suas capacidades de sentir e agir no mundo físico de forma autônoma e intencional (Matarić, 2014). Um robô é um sistema autônomo que existe no mundo físico, pode sentir o seu ambiente e pode agir sobre ela para alcançar alguns objetivos (Matarić, 2014). Para esta área, o uso de ML teve muitas contribuições como a maior precisão nos movimentos de robôs móveis, uma melhor exploração e mapeamento autônomos que particularmente são um dos desafios abertos da robótica e da IA [P121]. O trabalho [P118] aborda a contribuição da ML para resolução do problema de rastreamento e reconhecimento de estruturas da superfície da água para realização de um pouso dinâmico. Outra abordagem é a utilização para melhorar o controle de veículos autônomos com a finalidade de proporcionar maior segurança no trânsito, como citado no trabalho [P124].

A outra área citada foi a de Segurança, onde 13 artigos a mencionam. Essa área abrange uma variedade de contextos e setores, com o objetivo geral de proteger pessoas, ativos e informações contra ameaças, danos ou perigos. Utilizar a ML trouxe diversos benefícios para essa área, como, por exemplo, detecção de invasões em redes com mudanças de comportamento do tráfego na rede [P75], detecção de usuários impostores por meio de autenticação contínua em smartphones [P80], ou até mesmo na segurança pública, como a detecção de eventos de segurança pública como tiroteios, operações policiais, assaltos, roubos, entre outros, através de análise de publicações na rede social Twitter [P94].

A Organização Mundial de Saúde (OMS) define saúde como um estado de completo bem-estar físico, mental e social (OMS, 1946). Nessa área a ML teve grandes contribuições como melhorar a precisão de diagnóstico de COVID-19 ([P102] e [P19]), bem como acelerar outros processos, como detecção da presença de pneumonia através de imagens [P22], que podem fazer toda a diferença quanto ao tratamento de um paciente. Uma contribuição adicional, com impacto direto na saúde pulmonar, consiste na automação de sensores por meio de ML, esse avanço possibilita a classificação das condições do ar interno em edifícios [P25]. O propósito desse sistema é facilitar a diminuição da entrada de poluentes atmosféricos, proporcionando uma gestão eficiente da qualidade do ar interior [P25].

A área de Agricultura possuiu 11 citações, sendo que no Brasil desempenha um papel crucial como um setor econômico de grande impacto no Produto Interno Bruto (PIB) do País, tanto de maneira direta quanto indireta (Sartin *et al.*, 2020). Automatizar e melhorar processos que envolvam a agricultura são projetos promissores, como, por exemplo, realizar diagnóstico de doenças nas culturas de milho através e análise de imagem [P11], ou até mesmo auxiliar na classificação automatizada de sementes de soja para determinação de vigor e qualidade [P100]. A ML foi utilizada ainda para melhorar o processo de detecção de vegetação invasora, que pode causar impactos adversos irreversíveis na biodiversidade e afetar a produtividade econômica em setores como a pesca, a silvicultura e a agricultura [P127].

Conforme mostrado na Tabela 4, a ML é utilizada em diversas áreas que se diferem entre si, isso mostra que a ML pode e melhora processos em diversos campos, modernizando a abordagem tradicional e oferecendo soluções inovadoras. Essa diversidade de aplicação ressalta a capacidade da ML de aprimorar processos em vários domínios, ao mesmo tempo em que revoluciona abordagens tradicionais e apresenta soluções inovadoras. Além disso, o contínuo avanço tecnológico e a crescente disponibilidade de dados têm acelerado ainda mais a adoção da ML em diversos setores, impulsionando sua aplicação e impacto de forma significativa

Em relação à **QP2 “Quais aplicações mais relevantes dentro de cada área?”**, após a leitura das 147 publicações, foi possível perceber que cada uma citava várias aplicações das áreas da Tabela 4, o que causaria uma extensa discussão de resultados. Dessa maneira, foram selecionadas as 5 áreas mais citadas para destacar as aplicações, enquanto as aplicações das demais áreas podem ser encontradas nas Tabelas A2 a A12 no Apêndice. A Tabela 5 a seguir apresenta as aplicações na área da Computação.

Tabela 5 - Aplicações na área da Computação

- Análise de performance do modelo BERT para o cruzamento de domínios na classificação de sentimentos em bases de dados em português buscando compreender as emoções e opiniões expressas em dados textuais [P05]
- Automatização do processo de triagem dos relatórios de erros que são bugs reportados após os testes de software na área de Engenharia de Software [P06]
- Avaliação da ferramenta de métodos de reconhecimento de entidades nomeadas REN para as variantes europeia e brasileira da Língua Portuguesa [P14]
- Identificação de emoções através da fala pretendendo melhorar a interação entre humanos e sistemas [P16]
- Análise dos dados esportivos do futebol brasileiro para compreender o desempenho individual e coletivo dos atletas [P28]
- Análise de grandes volumes de dados educacionais para descoberta de conhecimento e melhora na compreensão dos desafios da educação básica [P34]
- Geração automática de legendas para imagens podendo ser aplicada para melhorar a compreensão, acessibilidade e eficácia em várias áreas [P53]
- Classificação de grafos como sendo de lei de potência para tornar a solução de problemas mais fácil [P55]
- Automatizar o projeto de redes profundas para melhorar o desempenho e facilitar a otimização dos parâmetros envolvidos usando princípios de programação genética [P60]
- Classificação Automática de Expressão Facial para oferece insights valiosos sobre o estado emocional das pessoas [P66]
- Agente que aprende lendo textos da web para expandir a base de conhecimento [P68]
- Recomendação de produtos para usuários que não possuem conhecimento técnico ajudando compradores a escolher o produto certo [P71]
- Uso de diferentes modelos de Machine Learning para segurança em IOT buscando melhorar a cibersegurança [P79]
- Detecção de invasões em dispositivos IOT para a melhora nos sistemas de cibersegurança [P81]
- Detecção ataque a dispositivos IoT tornando alvos mais difíceis para invasões [P83]
- Descoberta de Padrões de Defeito em Software JavaScript devido à diversidade de ambientes e situações em que esses códigos são desenvolvidos [P103]
- Identificação de classes que são mais propensas a mudanças durante o desenvolvimento de software buscando impactos positivos na produtividade [P107]
- Previsão de defeitos no código contribuindo para um processo de desenvolvimento mais eficiente [P108]
- Ferramenta que avalia a qualidade do software através de métricas de qualidade ajudando na avaliação da saúde de projetos de software [P109]
- Automação de ferramenta para teste de aplicativos móveis proporcionando eficiência, consistência e qualidade ao processo de garantia da qualidade software [P110]
- Framework que avalia a qualidade do Teste de Software com base na mineração dos testes e métricas de Machine Learning buscando garantir a qualidade software [P111]
- Detecção de Code Smell uma prática de programação em um código-fonte que podem indicar problemas ou fragilidades no design e na manutenção do software [P112]
- Ferramenta que avalia as más práticas de implementação de Arquiteturas do Software através de métricas de Machine Learning e Mineração de Dados [P113]
- Classificação do grau de nocividade do Code Smells buscando garantir a qualidade dos softwares [P114]
- Classificação automática de requisitos de software dentro da base de dados PROMISE para automatização da tarefa [P115]
- Uso de Word Embeddings para classificação de palavras na Engenharia de Software, sendo capaz de reconhecer termos específicos e relevantes desse contexto, permitindo identificar a semântica específica das palavras da área [P116]
- Reconhecimento de macro expressões faciais em humanos contribuindo para experiências mais intuitivas e personalizadas [P130]
- Otimização de Rede Neural Convolutacional 1D para seu uso em sistemas embarcados com poucos recursos para o Reconhecimento de Atividade Humana [P134]

- Aumento da eficiência da memória cache, utilizando como estudo o Last Level Cache buscando a melhora do desempenho geral do sistema [P135]
- Otimizar tempo de execução edge computing respeitando as limitações de hardware usando sistemas distribuídos [P137]
- Modelo mais determinístico para uma curva de potência WT monitoramento de desempenho de turbinas, manutenção e previsão de potência reduzindo erros de modelagem [P141]
- Detectar placas de Licença do Mercosul (detector YOLOv3) para fornecer um grande volume imagens para treinar o processo de detecção de placas de licença [P142]

Fonte: Os Autores (2023)

Na área da Computação, a ML desempenha um papel crucial com aplicações notáveis em subáreas como a ES, TI, IoT e IA. No contexto da Manutenção de Software, ML possibilitou a detecção eficiente de *Code Smell* e a avaliação de classes propensas a mudanças na fase inicial do projeto, conforme discutido em [P107] e [P112]. Essas implementações visam aprimorar a qualidade do software, utilizando técnicas de ML para criar modelos de detecção com base em conjuntos de dados de treinamento, conforme destacado por (Oliveira *et al.*, 2020)

No domínio do Teste de Software, a ML foi empregada de maneira destacada na automatização de testes e na avaliação da adequação da execução desses testes, como evidenciado em [P111] e [P110]. Essas aplicações não apenas otimizam o processo de teste, mas também garantem a eficácia e confiabilidade dos testes realizados, representando um avanço significativo na prática de teste de software. Quanto à Arquitetura de Software, uma aplicação inovadora utilizou algoritmos de ML em uma ferramenta chamada *Inset*, conforme mencionado em [P113]. Essa ferramenta não apenas avalia, apenas, as más práticas na implementação da arquitetura, mas também incorpora métricas e técnicas de mineração de dados para proporcionar insights valiosos. Isso destaca a capacidade da ML não apenas de identificar possíveis melhorias na arquitetura de software, mas também de oferecer uma abordagem proativa na prevenção de práticas inadequadas.

No campo de TI, estudos que se destacam nessa área estão ligados a detecção de intrusões em ambientes de nuvem usando Redes Neurais Artificiais (RNAs) [P81] e detecção de ataques em redes IoT [P81]. Além de estar presente no campo de recomendações de produtos para usuários que não possuem conhecimento técnico específico sobre produtos [P71]. Algoritmos de ML foram utilizados ainda para gerar legendas para imagens que envolvem compreensão visual e processamento de linguagem [P53], além da identificação de emoções através da fala em amostra de áudios [P16]. A Tabela 6 cita as aplicações para área da Robótica.

Tabela 6 - Aplicações na área da Robótica

- Propor a utilização de Deep Reinforcement Learning combinada com um método Probabilistic Roadmap (PRM) para o transporte de objetos em ambientes complexos por robôs [P117]
- Processamento de Imagem para perceber o ambiente, proporcionando uma melhor compreensão para os Veículos Aéreos Não Tripulados realizarem suas tarefas [P118]
- Localização dos Veículos Guiados Automatizados no ambiente industrial [P119]
- Orientação dos manipuladores de um robô [P120]
- Mapeamento para a melhor locomoção de robôs em ambientes de planejamento de rotas baseados em representações dos ambientes [P121]
- Futebol de Robôs, controle do mecanismo de chute [P122]
- Detecção de anomalias no tráfego de rede no ROS (Sistema Operacional de Robôs) [P123]
- Controle de Veículos Autônomos [P124]

- Treinar e simular um robô móvel em diferentes ambientes internos em comparação com um processo tradicional de recompensa DRL [P125]
- Framework de aprendizagem virtual para treinar e desenvolver comportamentos específicos para robôs no contexto da competição IEEE Very Small Size Soccer baseada em Deep Reinforcement Learning [P127]
- Navegação de robôs móveis em ambiente doméstico [P128]
- Navegação de Veículos Aéreos Não Tripulados [P129]
- Reconhecimento Facial feita por robôs [P131]
- Controlar um robô através de um controle que utiliza gestos para enviar comandos de velocidade, utilizando câmera e visão computacional /Identificar os gestos [P132]

Fonte: Os Autores (2023)

Nas aplicações voltadas para a robótica, destacam-se avanços significativos, como a implementação de métodos avançados de *Deep Reinforcement Learning* (DRL). Em uma abordagem, um robô é capaz de aprender perfis de ação específicos, otimizando estratégias de transporte [P117]. Este enfoque representa um salto notável no campo, proporcionando ao robô uma capacidade aprimorada de adaptação e eficiência em suas atividades. A DLR também encontra aplicação na Navegação de Veículos Aéreos Não Tripulados (VANTs), usando abordagens baseadas em dados de localização e alcance esparsos para treinar o agente inteligente, como mencionado em [P129]. Essa aplicação não só representa uma progressão em direção à autonomia dos VANTs, mas também destaca melhorias na capacidade de mapeamento e localização. Isso inclui a criação de mapas precisos em tempo real, contribuindo para uma navegação mais precisa e segura.

Outra aplicação está relacionada à movimentação de um robô, envolvendo a criação de uma estratégia baseada em *Reinforcement Learning* (RL) para o controle preciso de orientação e posição de um manipulador robótico de seis graus de liberdade [P120]. Esse avanço não apenas eleva a precisão na execução de tarefas, mas também estabelece novos padrões para a manipulação eficiente em ambientes complexos. Na área esportiva, avanços notáveis foram alcançados no desenvolvimento de mecanismos físicos inspirados em chutes e passes imprevisíveis, usando o algoritmo de treinamento Adam. Essa inovação eleva a complexidade nos esportes e impulsiona a robótica esportiva [P122]. A criação de mecanismos para jogadas imprevisíveis contribui significativamente para a interseção entre tecnologia robótica e esportes, proporcionando novas possibilidades. A integração de Machine Learning em robôs sociais, especialmente com a abordagem de *One-Shot Learning* e reconhecimento facial [P131], destaca-se como uma área crucial, possibilitando interações mais intuitivas e personalizadas em ambientes humano-robô. A Tabela 7 apresenta as aplicações na área da Segurança.

Tabela 7 - Aplicações na área da Segurança

- Solução que autênticas assinaturas manuscritas para minimizar fraudes, principalmente verificando documentos históricos [P18]
- Pipeline para a detecção de sons invasores em residências [P75]
- Utilização de técnicas de Machine Learning para sistemas de detecção de intrusão baseados em rede considerando as mudanças de comportamento do tráfego [P77]
- Método de autenticação contínua usando sensores inerciais de smartphones para maior segurança de dados pessoais [P80]
- Realizar a detecção de anomalias em redes de computadores [P82]
- Detecção de ataque a rede TCP de dispositivos usando Machine Learning [P84]
- Detecção de uso incorreto de criptografia em aplicações Java [P85]

- Detecção de ataque em aplicações web usando filtro de Bloom e técnicas de Machine Learning já usadas para a detecção de anomalias em ataques web [P86]
- Detecção de imagens pornográficas em dispositivos computacionais para aumentar a eficiência em exames periciais [P87]
- Detecção e reconhecimento de usuários baseado na dinâmica da digitação, utilizando algoritmos de Aprendizado de Máquina [P88]
- Metodologia de extração automática de conhecimento, na forma de estatísticas relacionadas a eventos de segurança pública (tiroteios, operações policiais, assaltos, roubos, sequestros, entre outros), a partir de microtextos publicados gratuitamente em redes sociais. [P94]
- Combinação de informações estruturadas de anúncios e informações de imagens para a detecção de fraudes no comércio eletrônico [P101]
- Método que utiliza redes neurais profundas para classificar malwares em famílias, com base na análise do código desmontado, explorando a capacidade da rede de identificar padrões sem depender de recursos de especialistas [P104]

Fonte: Os Autores (2023)

A aplicação de ML na área de Segurança abrange uma diversidade de setores, desde a segurança pública até a segurança pessoal, evidenciando sua versatilidade e impacto abrangente. No âmbito da segurança pública, os algoritmos de ML demonstraram sua eficácia ao serem empregados em uma metodologia inovadora de mineração automatizada de microtextos em redes sociais, conforme evidenciado na [P94]. No que diz respeito à segurança pessoal, destaca-se a aplicação de algoritmos para aprimorar métodos de autenticação contínua em dispositivos móveis, conforme descrito na [P80]. Essa forma avançada de autenticação envolve a verificação contínua da autenticidade do usuário durante todo o uso do dispositivo, proporcionando uma camada adicional de segurança aos dados do usuário.

Outra aplicação nesta área utiliza da ML para o monitoramento de ambientes inteligentes. Essas inovações não apenas conseguem identificar sons característicos de eventos invasivos, como tentativas de arrombamento, mas também operam como sistemas de segurança ou alarmes eficazes [P75]. Ademais, no contexto das redes de computadores o progresso contínuo nas redes tem ampliado a incidência de ataques cibernéticos, tornando imperativa a implementação de soluções dedicadas à segurança de redes. Pesquisas que buscam identificar ataques em estágios iniciais [P84], identificar ataques por meio de assinaturas e comportamentos avaliando o desvio do comportamento esperado para identificar ameaças [P77], desempenham um papel crucial ao atuarem como sistemas de detecção de intrusões.

Além disso, no contexto das redes de computadores o progresso contínuo nas redes tem ampliado a incidência de ataques cibernéticos, tornando imperativa a implementação de soluções dedicadas à segurança de redes. Pesquisas que buscam identificar ataques em estágios iniciais [P84], identificar ataques por meio de assinaturas e comportamentos avaliando o desvio do comportamento esperado para identificar ameaças [P77], desempenham um papel crucial ao atuarem como sistemas de detecção de intrusões (IDS). A Tabela 8 apresenta as aplicações na área da Saúde.

Tabela 8 - Aplicações na área da Saúde

- Auxílio no diagnóstico da COVID-19 em pacientes suspeitos com base em dados de exames laboratoriais clínicos [P19]
- Detecção e classificação de pneumonia a partir de uma coleção de imagens de raios-x do tórax. [P22]
- Identificação de casos de Covid-19 através de imagens raio-x oferecendo uma ferramenta adicional para o diagnóstico e controle de doenças infecciosas [P23]
- Clusterização de imagens de fraturas de compressão vertebral para entender características e dificuldades na diferenciação de classes contribuindo para uma análise de imagens médicas aprimorada [P24]
- Classificação de leituras de sensores de qualidade do ar interno buscando diminuir falsos positivos [P25]
- Classificação de padrões de corrida associados à fadiga para destacar padrões de corrida mais eficientes [P35]
- Identificação de dislexia através da análise de movimentos oculares durante a leitura buscando um diagnóstico menos complexo e acessível [P39]
- Previsão do número de casos de dengue usando variáveis climáticas prevenindo focos de transmissão de doenças [P54]
- Classificação de imagens para reconhecimento de tuberculose proporcionando uma abordagem automatizada e eficiente para a interpretação de imagens médicas [P59]
- Classificação de alimentos e estimulação de valores nutricionais ajudando no monitoramento e controle alimentar [P67]
- Detecção de estresse pela variação de frequência cardíaca buscando uma melhor qualidade de vida e bem-estar cardíaca [P76]
- Ferramenta de inferência automática do nível calórico de receitas através da Classificação de Textos proporcionando uma abordagem automatizada para avaliar o conteúdo nutricional de receitas [P95]
- Predição de tendências de abandono de pacientes em Programas de Reabilitação Pulmonar proporcionando o desenvolvimento de técnicas para permanência dos pacientes [P99]
- Previsão da necessidade de hospitalização de pacientes com COVID-19 melhorando a tomada de decisões e gerenciamento de recursos [P102]

Fonte: Os Autores (2023)

Na esfera da Saúde, a ML desempenhou um papel significativo em uma série de aplicações inovadoras, das quais destacamos algumas para ilustrar sua amplitude e contribuição. Um exemplo notável é a utilização de algoritmos genéticos em conjunto com um classificador para prever a necessidade de hospitalização em pacientes com COVID-19, conforme evidenciado na [P102]. Outra aplicação relevante na luta contra a COVID-19 é o desenvolvimento de um modelo preditivo, descrito na [P19], que utiliza exames laboratoriais para realizar diagnósticos precoces da doença. Essa abordagem representa um avanço significativo na detecção rápida e eficaz da COVID-19, contribuindo para estratégias de tratamento mais ágeis.

No campo das Redes Neurais, uma categoria essencial da ML, observamos sua aplicação na detecção de tuberculose em radiografias de tórax por meio de métodos neurais convolucionais, conforme destacado em [P59]. Essa tecnologia não apenas aprimora a precisão dos diagnósticos, mas também agiliza o processo, proporcionando benefícios tangíveis para o tratamento precoce e eficaz. Na Neuropsicologia, a aplicação voltada para a dislexia, um transtorno de aprendizagem que impacta as habilidades linguísticas, prejudicando notadamente a leitura e a compreensão de textos, tem se mostrado extremamente promissora no diagnóstico. Especificamente, o rastreamento dos movimentos oculares durante a leitura tem se destacado como uma ferramenta valiosa para melhorar a compreensão dos padrões visuais e identificar características específicas associadas à dislexia [P39]. O emprego de tecnologias inovadoras

como ML na Neuropsicologia representa uma contribuição significativa para a compreensão e o tratamento dessa condição.

Além disso, as Redes Neurais foram empregadas na detecção e classificação de pneumonia a partir de imagens de Raio-X [P22]. Essa aplicação não apenas aprimora a eficiência do diagnóstico, mas também representa um avanço crucial na identificação de condições pulmonares, o que é especialmente relevante em ambientes clínicos. Essas aplicações na área de Saúde destacam a versatilidade da ML em fornecer soluções inovadoras e impactantes, contribuindo para diagnósticos mais precisos, tratamentos mais eficazes e, em última análise, melhorias substanciais na qualidade do cuidado ao paciente. A Tabela 9 apresenta as aplicações na área da Agricultura.

Tabela 9 - Aplicações na área da Agricultura

- | |
|---|
| <ul style="list-style-type: none"> • Análise de dados agrícolas para classificação de municípios, agrupando regiões que se assemelham de acordo com suas particularidades regionais de produção agrícola [P08] • Diagnóstico de doenças nas culturas de milho através e análise de imagem com enfoque na detecção precoce [P11] • Classificação de espécies de plantas buscando identificar corretamente a espécie de uma planta sem uso de especialistas [P26] • Classificação da deficiência de potássio nas folhas de soja melhorando a eficiência, a precisão e a sustentabilidade nas práticas agrícolas [P27] • Identificação automatizada de espécies de plantas a partir de imagens promovendo uma agricultura mais sustentável e produtiva [P40] • Classificação de grãos de cacau através de imagens resultando em produtos de melhor qualidade [P42] • Identificar doenças a partir de imagens de folhas de uva promovendo práticas mais sustentáveis e eficientes na viticultura [P64] • Classificação de folhas para denominar a espécie de planta proporcionando uma abordagem mais eficiente e precisa para a identificação de espécies de plantas [P70] • Classificação automatizada de sementes de soja para determinação de vigor e qualidade buscando diminuir erros e recursos [P100] • A detecção remota e autônoma de vegetação invasora em áreas grandes minimizando acidentes biológicos [P126] • Identificação e classificação de plantas como culturas ou ervas daninhas proporcionando a intervenção precoce [P139] |
|---|

Fonte: Os Autores (2023)

A agricultura demonstra significativos benefícios ao incorporar técnicas de ML para otimizar diversas tarefas. Um exemplo notável é a aplicação da Rede Neural Convolutiva (RNC) no processamento de imagens em plantações, com foco na classificação da deficiência do macronutriente potássio nas folhas de soja [P27]. Esse estudo ilustra como a ML pode ser instrumental na identificação precoce de problemas nutricionais em plantações, permitindo uma intervenção eficiente e otimizando a saúde das culturas. Adicionalmente, a aplicação de técnicas de ML na classificação de grãos de cacau por meio de imagens destaca a notável capacidade dessas tecnologias em aprimorar a qualidade e uniformidade dos produtos agrícolas, conforme evidenciado no estudo referenciado como [P42].

Paralelamente, a automação do processo de análise foliar em vinícolas, conforme apresentado em [P64], destaca-se como uma aplicação inovadora. Dada a importância crítica da análise foliar para monitorar a saúde das videiras, a automação desse processo não apenas representa uma economia de tempo e recursos, mas também fornece informações altamente

precisas para embasar decisões agronômicas fundamentais. Ademais, a classificação automática do vigor de sementes de soja [P100], a avaliação do vigor destaca-se como aspecto crucial na produção de sementes de soja, determinando o potencial das sementes para germinar e crescer em diversas condições de campo. Essas tecnologias não só melhoram a eficiência e precisão das práticas agrícolas, mas também promovem uma abordagem mais sustentável e informada na gestão dos recursos.

Ademais, a classificação automática do vigor de sementes de soja [P100], a avaliação do vigor destaca-se como aspecto crucial na produção de sementes de soja, determinando o potencial das sementes para germinar e crescer em diversas condições de campo. Essas diversas aplicações ilustram de maneira contundente como as técnicas de ML têm se firmado como ferramentas indispensáveis na agricultura contemporânea. Ao oferecer soluções inovadoras para demandas específicas, essas tecnologias não apenas ampliam a eficiência e a precisão das práticas agrícolas, mas também abrem caminho para uma abordagem mais sustentável e informada na gestão dos recursos agrícolas.

Com relação à **QP3 “Quais são os principais algoritmos utilizados?”**, foram identificados 62 algoritmos, conforme a Tabela 10. Dentre eles, serão discutidos os 7 que apresentaram uma quantidade de 30 ou mais citações, conforme mostra a Figura 5.

Tabela 10 – Algoritmos

| Nome | Artigos | Quantidade |
|-------------------------------------|---|------------|
| Random Forest (EF) | [P01], [P03], [P04], [P05], [P06], [P13], [P19], [P20], [P25], [P26], [P28], [P33], [P34], [P39], [P41], [P48], [P49], [P50], [P52], [P54], [P55], [P62], [P63], [P68], [P71], [P73], [P74], [P78], [P82], [P83], [P86], [P87], [P88], [P89], [P96], [P97], [P98], [P99], [P100], [P101], [P106], [P107], [P111], [P112], [P114], [P133], [P135] e [P140] | 48 |
| k-Nearest Neighbors (K-NN) | [P01], [P06], [P19], [P20], [P22], [P25], [P26], [P33], [P34], [P39], [P42], [P43], [P44], [P46], [P47], [P48], [P54], [P55], [P56], [P62], [P65], [P68], [P69], [P70], [P71], [P73], [P75], [P76], [P78], [P86], [P88], [P90], [P93], [P96], [P98], [P100], [P101], [P106], [P114], [P115], [P137], [P140], [P145] e [P147] | 44 |
| Support Vector Machine (SVM) | [P01], [P05], [P06], [P09], [P19], [P20], [P26], [P33], [P36], [P37], [P38], [P39], [P44], [P45], [P46], [P48], [P50], [P52], [P55], [P62], [P69], [P71], [P73], [P74], [P76], [P79], [P85], [P86], [P88], [P91], [P95], [P97], [P99], [P100], [P101], [P106], [P111], [P112], [P114], [P115], [P123], [P135], [P136] e [P147] | 44 |
| Decision Tree (DT) | [P01], [P03], [P04], [P19], [P22], [P34], [P39], [P42], [P43], [P44], [P46], [P50], [P61], [P62], [P65], [P68], [P71], [P73], [P78], [P79], [P82], [P83], [P84], [P86], [P87], [P89], [P92], [P96], [P97], [P99], [P100], [P101], [P102], [P105], [P107], [P111], [P114] e [P115] | 38 |
| Siamese Convolutional Network (CNN) | [P07], [P11], [P12], [P15], [P16], [P18], [P27], [P30], [P32], [P37], [P47], [P50], [P53], [P59], [P60], [P64], [P66], [P67], [P75], [P80], [P82], [P83], [P105], [P110], [P118], [P126], [P128], [P130], [P132], [P134], [P136], [P139], [P142], [P143], [P144] e [P146] | 35 |

| | | |
|---|--|----|
| Multi-Layer Perceptron (MLP) | [P03], [P07], [P22], [P25], [P29], [P35], [P36], [P37], [P39], [P42], [P43], [P45], [P46], [P47], [P52], [P54], [P57], [P62], [P68], [P71], [P75], [P78], [P79], [P81], [P83], [P86], [P87], [P88], [P89], [P97], [P98], [P100], [P101] e [P104] | 34 |
| Naive Bayes (NB) | [P01], [P05], [P09], [P17], [P19], [P22], [P33], [P36], [P39], [P42], [P43], [P44], [P46], [P52], [P62], [P65], [P68], [P71], [P76], [P79], [P83], [P95], [P96], [P97], [P105], [P112], [P114], [P115], [P135] e [P145] | 30 |
| Logistic Regression (LR) | [P01], [P05], [P06], [P16], [P33], [P36], [P41], [P50], [P52], [P79], [P95], [P96], [P101], [P106], [P106] e [P111] | 16 |
| Long Short-Term Memory (LSTM) | [P29], [P58], [P78], [P80], [P83], [P86], [P88] e [P134] | 8 |
| Extreme Gradient Boosting (XGBoost) | [P03], [P19], [P51], [P66], [P74], [P79] e [P96] | 7 |
| K-Means | [P08], [P21], [P24], [P34], [P58], [P61] e [P103] | 7 |
| Gradient Boosting (GB) | [P03], [P04], [P19], [P55], [P96], [P106], [P114] | 7 |
| Adaptive Boosting (AdaBoost) | [P03], [P39], [P61], [P82] e [P96] | 5 |
| Rede Neural Artificial (ANN) | [P44], [P48], [P63], [P69] e [P86] | 5 |
| Proximal Policy Optimization (PPO) | [P120], [P121], [P124] e [P127] | 4 |
| Linear Support Vector Machine (Linear SVM) | [P41], [P39], [P68] e [P96] | 4 |
| Support Vector Classifier (SVC) | [P17], [P68] e [P96] | 3 |
| Support Vector Classifier Linear (SVC Linear) | [P68], [P96] e [P41] | 3 |
| Multinomial Naive Bayes (MNB) | [P17], [P44] e [P105] | 3 |
| Support Vector Regression (SVR) | [P03], [P04] e [P133] | 3 |
| CatBoost | [P03], [P74] e [P93] | 3 |
| Light Gradient Boosting (LBG) | [P74], [P96] e [P89] | 3 |
| Generative Adversarial Network (GANs) | [P18], [P23] e [P77] | 3 |
| Isolation Forest (IF) | [P51], [P136] e [P137] | 3 |
| Deep Deterministic (DDPG) | [P118], [P120] e [P129] | 3 |
| Rede Neural Network (RNN) | [P07], [P16] e [P58] | 3 |
| Residual neural network (ResNet) | [P16], [P53] e [P58] | 3 |
| Gaussian Naive Bayes (GNB) | [P101] e [P114] | 2 |
| Perceptron | [P68] [P135] | 2 |
| Algoritmos genéticos (GA) | [P60] e [P102] | 2 |
| One Rule (OneR) | [P112] e [P71] | 2 |
| JRip Rules (JRip) | [P71] e [P112] | 2 |
| YOLO | [P119] e [P146] | 2 |
| Q-learning | [P117] e [P125] | 2 |
| Extra Tree (ET) | [P19] e [P96] | 2 |
| Weighted k-Nearest Neighbors (WKNN) | [P26] | 1 |
| Tree Augmented Naive Bayes (TAN) | [P46] | 1 |
| Optimum-Path Forest (OPF) | [P100] | 1 |
| Fuzzy C-Means (FCM) | [P103] | 1 |

| | | |
|---|--------|---|
| Density-Based Spatial Clustering (DBScan) | [P103] | 1 |
| Hierarchical Density-Based Spatial Clustering (HDBScan) | [P103] | 1 |
| Rede Bayesiana (BN) | [P106] | 1 |
| Deep Belief Net (DBNs) | [P88] | 1 |
| Convolutional Neural Network bidimensional (2DCNN) | [P83] | 1 |
| Autoencoders (AE) | [P83] | 1 |
| Agglomerative Hierarchical Clustering (AHC) | [P61] | 1 |
| K-sets models (Klll) | [P69] | 1 |
| Stochastic Gradient Descent (SGD) | [P68] | 1 |
| Deep Feedforward Network (DFN) | [P72] | 1 |
| Extreme Learning Machine (ELM) | [P40] | 1 |
| Bayesian Ridge Regressor (BRR) | [P54] | 1 |
| Multichannel CNN Trading Classifier (MCNN-TC) | [P31] | 1 |
| One-short Learning | [P131] | 1 |
| Soft Actor Critic (SAC) | [P129] | 1 |
| Deep Q-networks | [P125] | 1 |
| Adam | [P122] | 1 |
| RNA | [P141] | 1 |
| Rede Neural Network | [P07] | 1 |
| Faster R-CNN | [P139] | 1 |
| Angle-Based Outlier Detection (ABOD) | [P137] | 1 |
| One-Class Support Vector Machine (OCSVM) | [P137] | 1 |
| Siamese Convolutional Network | [P140] | 1 |

Fonte: Os Autores (2023)

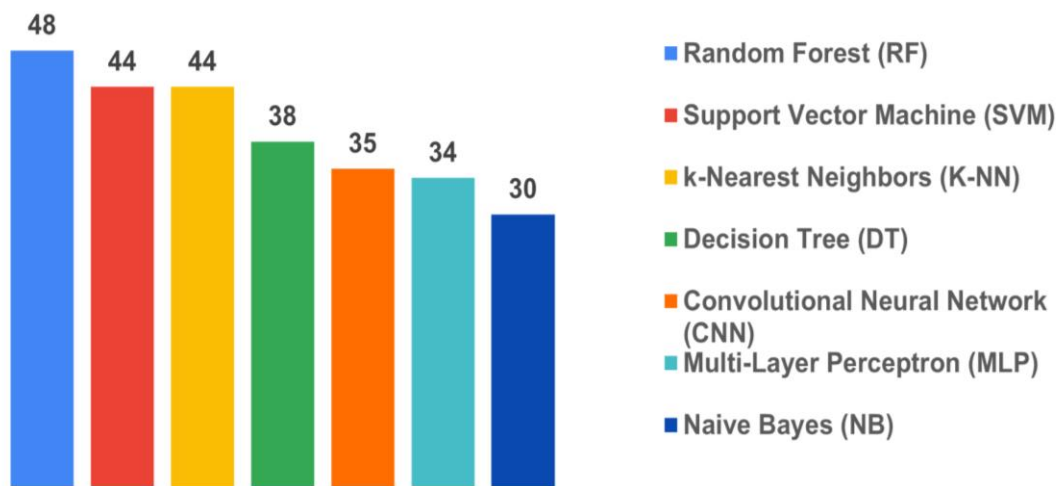


Figura 5 - Os 7 algoritmos com 30 ou mais citações

Fonte: Os Autores (2023)

O algoritmo *Random Forest* (RF), foi citado em 48 publicações, sendo um método que utiliza uma combinação de Árvores de Decisão para prever resultados com base em regras simples. A utilização de múltiplas árvores visa mitigar efeitos adversos de ruídos e discrepâncias, tornando o classificador mais robusto (Criminisi, Konukoglu e Shotton, 2012).

No comparativo de cinco modelos de classificadores utilizados frequentemente em sistemas para detecção de fraudes em cartões de crédito [P33], os melhores resultados foram obtidos com modelos de RF. Uma vantagem adicional deste classificador é a sua maior robustez em relação à escolha das configurações de balanceamento e seleção de atributos (Nicola, Lauretto e Delgado, 2018). No âmbito de classificar músicas em seus respectivos gêneros musicais, o RF combinado com outros modelos, obteve uma acurácia máxima de 80,64% [P48]. O RF foi empregado em uma combinação cujo objetivo foi identificar as classes mais suscetíveis a mudanças no ciclo de desenvolvimento de software [P107]. Entre os vários algoritmos testados, o RF se destacou, demonstrando consistentemente os melhores resultados na maioria dos estudos pré-implementação.

O algoritmo K-NN obteve citação em 44 publicações, utilizando em diversas áreas. O algoritmo K-NN opera com o princípio de que amostras semelhantes, pertencentes à mesma classe, têm alta probabilidade de estar próximas umas das outras. Em geral, o K-NN identifica inicialmente os k vizinhos mais próximos de uma consulta no conjunto de dados de treinamento e, em seguida, prevê a classe da consulta com base na classe predominante entre esses k vizinhos mais próximos (Rego e Nunes, 2019).

No artigo [P145], o K-NN foi utilizado junto de outro algoritmo, o *Naive Bayes*, para uma aplicação para identificar degradação em isoladores poliméricos de alta tensão utilizando emissões ultrassônicas. Nessa aplicação os resultados mostraram que K-NN possui melhor precisão de classificação que Bayes. Na área da saúde, o algoritmo k-NN foi aplicado com êxito na detecção da presença de pneumonia a partir de uma coleção de imagens de raios-X de tórax, alcançando uma acurácia máxima de 80,44%. Essa abordagem oferece uma perspectiva promissora para aprimorar os diagnósticos médicos, permitindo uma identificação mais eficaz de condições pulmonares por meio de análises computacionais, não apenas demonstrando o potencial da ML na área da saúde, mas também destaca a capacidade dessas tecnologias em complementar o trabalho de profissionais médicos.

O SVM foi utilizado em 45 publicações, esse algoritmo consiste em uma técnica de classificação que se fundamenta na teoria de aprendizado estatístico. Originalmente projetado para resolver problemas de classificação, o SVM evoluiu ao longo do tempo, expandindo sua aplicação para incluir a resolução de problemas de regressão (Chamasemani e Singh, 2011). Na área da saúde, esse algoritmo foi empregado em uma aplicação voltada para analisar os históricos de cinco indivíduos, visando classificar o estresse mental com base na variabilidade da frequência cardíaca [P76]. Nessa aplicação, o SVM se destacou como o algoritmo de melhor desempenho nos testes realizados, alcançando uma acurácia de 82% e um F1-Score de 75%.

Na área de segurança, foi implementado um classificador de cenas acústicas para detectar violência doméstica [P38], o SVM se demonstrou bastante promissor com uma acurácia média de 74%. Esses números destacam a robustez e o potencial do SVM na

identificação de padrões em contextos de segurança, contribuindo para aplicações práticas e eficazes nesse cenário.

A *Decision Tree* (DT) foi citada em 38 publicações. As “Árvores de Decisão” são métodos de classificação de dados no contexto da chamada de *Data Mining*, e são as únicas a apresentar os resultados hierarquicamente (Lemos, Steiner, Nievola, 2005). Segundo Garcia (2000), as árvores de decisão são modelos simples para construir classificadores baseados em atributos de um conjunto de dados. Na área de Direito e Justiça uma de suas aplicações foi para a classificação de comunicados de irregularidades em Ouvidorias Públicas de Tribunais de Contas, onde atingiu uma acurácia média de 0.84% [P01]. Na Saúde está sendo utilizado em diversas aplicações, onde uma delas foi o desenvolvimento de um modelo preditivo para auxiliar na identificação de infecção por COVID-19 em pacientes suspeitos com base em dados de exames laboratoriais clínicos, neste estudo o algoritmo resultou em uma acurácia de 0.877% [P19].

A CNN foi destacada em 35 artigos, ela é uma rede neural que processa dados dispostos em forma matricial, como imagens 1D, 2D ou 3D, utilizando a operação de convolução como sua característica distintiva. Essa operação matemática é uma ferramenta poderosa que junta duas funções para expressar uma alteração ocorrida nelas, facilitando a implementação e tornando a rede mais rápida e eficiente (Godinho, 2020). Na Computação a CNN tem desempenhado grandes avanços. O uso desses modelos oferece uma abordagem viável para ajudar na manutenção de aeronaves, especialmente na monitorização da saúde e na detecção de falhas, que após os testes foi contatado uma precisão de 0,9937% [P07], consolidando a eficácia desses modelos na manutenção de aeronaves e na prevenção de possíveis problemas. Na Agricultura, o emprego de CNNs para o diagnóstico de doenças nas culturas de milho por meio da análise de imagem tem revelado promissoras aplicações, alcançando uma acurácia máxima de 97.29% com boa precisão [P11].

O MLP foi citado em 34 artigos, é caracterizado como uma rede neural composta por vários elementos situados entre a camada de entrada e a camada de saída, sendo esses elementos referidos como neurônios, destaca-se a capacidade de ajustar as camadas de acordo com a complexidade da saída desejada (Ramchoun *et al.*, 2016). A Gestão Pública abrange um amplo espectro de atividades voltadas para a administração eficaz de recursos, serviços e políticas públicas, visando atender às demandas da sociedade. Dentro desse contexto, destaca-se um estudo relevante que utiliza uma MLP para a previsão mensal do ICMS no Estado do Rio de Janeiro, demonstrando uma notável redução na taxa de erro [P29]. Explorando outras aplicações, surgem estudos focados na classificação de padrões de corrida associados à fadiga [P35]. Esse método apresenta potencial para aprimorar a prevenção de lesões e otimizar a biomecânica da corrida, evidenciando a versatilidade e sucesso da aplicação desse algoritmo.

O NB foi usado em 30 artigos, ele se baseia na teoria da decisão estatística e utiliza o Teorema de Bayes para calcular a distribuição de probabilidade dos padrões em cada classe. Apesar de sua simplicidade, o NB demonstra eficácia notável, muitas vezes rivalizando com classificadores mais complexos e sua abordagem direta e resultados consistentes fazem dele uma escolha valiosa em diversas aplicações de classificação (Durgiewicz, 2021). Este algoritmo tem uma presença significativa em diversos setores, incluindo a área de Direito e Justiça. Um

exemplo notável é a sua aplicação na classificação de transações fraudulentas em cartões de crédito [P33]. Essa abordagem destaca a capacidade do algoritmo em identificar padrões suspeitos e tomar decisões rápidas, contribuindo assim para a segurança e integridade das transações financeiras.

O NB proporciona uma abordagem eficiente para analisar e categorizar comunicados, contribuindo para uma gestão mais ágil e eficaz de questões relacionadas à transparência e responsabilidade. No âmbito da Saúde, podemos citar um exemplo da utilização desse algoritmo no processo de detecção de estresse pela variação de frequência cardíaca [P76], pois o estresse mental afeta negativamente a saúde física e emocional. Essa versatilidade do NB destaca o potencial e a aplicabilidade do NB em diversas esferas, consolidando sua posição como um método robusto de classificação.

Diante da extensa análise dos principais algoritmos de aprendizado de máquina - RF, K-NN, SVM, pode-se notar que esses algoritmos não apenas ilustram a crescente influência da aprendizagem de máquina em várias esferas, mas também reforçam a importância de abordagens computacionais na resolução de problemas complexos, oferecendo perspectivas promissoras para o futuro da tecnologia e inovação em diversos setores.

7. CONSIDERAÇÕES FINAIS

A ML representa uma revolução no campo da IA, oferecendo uma abordagem inovadora para a resolução de problemas complexos e tem sido uma área de pesquisa ativa por décadas, mas só recentemente começou a ter um impacto significativo em nossas vidas em diferentes esferas sociais. Nesse sentido, foi realizado um MS com o objetivo de proporcionar uma visão abrangente do atual impacto da ML, através de três questões de pesquisas. A análise de 147 publicações selecionadas permitiu a identificação de distintas áreas de aplicação, destacando as variadas contribuições e algoritmos empregados nesse contexto.

Como resultado, foram identificadas 16 áreas de aplicação, dentre elas a Computação, que emerge como a mais proeminente no uso de ML, também exerce um impacto significativo em diversos outros campos como: Robótica, Ciências Sociais, Ciências Humanas, Gestão Pública, Agricultura, Saúde, Segurança da Informação, dentre outros. Em cada domínio mencionado, essa abordagem contribui de maneira notável para a análise avançada de dados e otimização de processos, demonstrando sua versatilidade e relevância generalizada.

Com relação as aplicações, foram relacionadas 147, em diferentes cenários, finalidades, execuções e resultados, como classificação de espécies de plantas, mapeamento de espaços e auxílio no diagnóstico de doenças. Muitas das aplicações incluíram comparações entre métodos tradicionais e o emprego de algoritmos de ML, evidenciando melhorias significativas nos processos nos quais a ML foi incorporada. A relevância da ML é claramente destacada por meio dessas aplicações, que demonstram seu impacto positivo na eficiência e na qualidade em diversas esferas. O aumento constante no uso da ML ressalta a importância crucial de profissionais capacitados nessa área, pois a crescente demanda por especialistas nesta técnica reflete a necessidade de aproveitar plenamente o potencial dessa tecnologia em constante evolução.

Nesse cenário, notou-se o uso predominante de 7 tipos de algoritmos, sendo eles: K-NN, SVM, RF, DT, CNN, MLP e NB. Os algoritmos mencionados têm características distintas, entretanto, há alguns pontos em comum e padrões observados em suas aplicações. Dentre os algoritmos analisados, o RF se destaca com 48 citações, revelando sua versatilidade em diferentes contextos. A robustez do RF é evidenciada em aplicações variadas, desde detecção de fraudes em cartões de crédito até a classificação de músicas e a identificação de classes suscetíveis a mudanças no ciclo de desenvolvimento de software. O SVM, citado em 44 estudos, também é mencionado por sua robustez em contextos de segurança. Ambos os algoritmos demonstram bons desempenhos em várias aplicações, contribuindo para a confiança em seus resultados. Portanto, cada algoritmo tem características específicas que os distinguem, porém, compartilham a capacidade de lidar com uma ampla gama de problemas e são frequentemente escolhidos com base nas demandas específicas de cada aplicação. Sua escolha muitas vezes depende das características dos dados, da natureza da tarefa e das necessidades específicas do problema em questão.

No entanto, à medida que a ML se torna mais onipresente, surgem também desafios e responsabilidades éticas. A rápida expansão dessa tecnologia levanta preocupações adicionais relacionadas à privacidade e segurança dos dados, tornando assim imperativo desenvolver estratégias robustas para proteger informações sensíveis e garantir que as decisões automatizadas sejam éticas e imparciais. Surge ainda a necessidade de criar métodos que permitam aos usuários compreenderem as decisões tomadas pelos modelos, promovendo assim a confiança na implementação dessas tecnologias.

Embora o trabalho tenha sido realizado cuidadosamente, é importante destacar algumas limitações relacionadas ao MS. Algumas edições de simpósios não estavam disponíveis na plataforma SOL, o que comprometeu a abrangência da análise dos estudos publicados naquele ano. Além disso, a funcionalidade de busca automática não estava operacional na plataforma, levando à necessidade de realizar uma busca manual. Esse processo mostrou-se cansativo e não abrangente, podendo ter resultado na omissão de artigos importantes na seleção final. Além disso, poderia ter sido consultada outras bases de dados que tenham relevância para a ML.

Como trabalhos futuros, recomenda-se considerar algumas melhorias e expansões da pesquisa já realizada. Uma proposta seria estender o MS para além dos simpósios inicialmente selecionados, incorporando a exploração de outros periódicos ou conferências relevantes ou internacionais. Além disso, aplicar novas questões de pesquisas relacionadas a uma determinada área específica e realizar uma análise de dados em relação aos algoritmos, descrevendo as vantagens e desvantagens de sua utilização e em qual contexto é melhor ser aplicado.

AGRADECIMENTOS

Esta pesquisa, realizada no âmbito do Projeto Samsung-UFAM de Ensino e Pesquisa (SUPER), de acordo com o Artigo 39 do Decreto nº 10.521/2020, foi financiada pela Samsung Eletrônica da Amazônia Ltda, nos termos da Lei Federal nº 8.387/1991, através do convênio 001/2020 firmado com a UFAM e FAEPI, Brasil.

REFERÊNCIAS

- Amorim, M.; Barone, D. e Mansu, A. (2008). **Técnicas de Aprendizado de Máquina Aplicadas na Previsão de Evasão Acadêmica**. XIX Simpósio Brasileiro de Informática na Educação (SBIE), Fortaleza. p. 666-674.
- Bishop, C. e Nasrabadi, N. (2006). **Pattern Recognition and Machine Learning**. 1. ed. New York: Springer.
- Chamasemani, F. e Singh, Y. (2011). **Multi-class Support Vector Machine (SVM) Classifiers--an Application in Hypothyroid Detection and Classification**. XVI International Conference on Bio-Inspired Computing: Theories and Applications, Malásia, p. 351-356.
- Criminisi, A., Konukoglu, E. e Shotton, J. (2012). **Decision Forests for Classification, Regression, Density Estimation, Manifold Learning and Semi-Supervised Learning**. Massachusetts: Now Pub.
- Dias, S.; Filgueiras, R.; Fernandes, F.; Arcanjo, G.; Silva, G.; Mantovani, E. e Cunha, F. (2021). **Reference Evapotranspiration of Brazil Modeled with Machine Learning Techniques and Remote Sensing**. Plos One, v. 16, n. 2, p. e0245834.
- Durgiewicz, R. (2021). **Detecção de Fake News Utilizando o Algoritmo Naive Bayes**. 37 f. Monografia (Ciência de Dados e suas Aplicações) - Universidade Tecnológica Federal do Paraná.
- Fernandes, A. (2003). **Inteligência Artificial: Noções Gerais**. 1. ed. Florianópolis: Visual Books.
- Garcia, A. (2020). **Ética e Inteligência Artificial**. Computação Brasil, n.43, p.14-22.
- Garcia, S. (2000). **O Uso de Árvores de Decisão na Descoberta de Conhecimento na Área da Saúde**. 88 f. Dissertação (Mestrado em Ciência da Computação) - Universidade Federal do Rio Grande do Sul.
- Géron, A. (2017). **Hands-on Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. 2. ed. Massachusetts: O'Reilly Media.
- Godinho, C. (2020). **Modelo de Financial Trading através de Redes Neurais Convolucionais**. 90 f. Dissertação (Mestrado em Matemática Financeira) - Universidade de Lisboa.
- Goodfellow, I., Bengio, Y. e Courville, A. (2016). **Deep Learning**. 1. ed. Massachusetts: MIT Press.
- Kaufman, D. (2019). **A Inteligência Artificial irá Suplantar a Inteligência Humana?** 1. ed. São Paulo: Estação das Letras e Cores.
- Kitchenham, B. e Charters, S. (2007). **Guidelines for Performing Systematic Literature Reviews in Software Engineering**. Relatório Técnico, Keele University e Durham University Joint Report, Disponível em: https://legacyfileshare.elsevier.com/promis_misc/525444systematicreviewsguide.pdf. Acesso em: 05. Set 2023.
- Lemos, E.; Steiner, M. e Nievola, J. (2005). **Análise de Crédito Bancário por Meio de Redes Neurais e Árvores de Decisão: Uma Aplicação Simples de Data Mining**. RAUSP Management Journal, v. 40, n. 3, p. 225-234.

- Lima, L. (2023). **Uma Abordagem de Teste de Integração com Planejamento em Inteligência Artificial**. Congresso Ibero-Americano em Engenharia de Software (Cibse), Montevideo, Uruguai, p. 261-268.
- Ludermir, T. (2021). **Inteligência Artificial e Aprendizado de Máquina: Estado Atual e Tendências**. Estudos Avançados, v. 35, n. 101, p. 85-94.
- Matarić, J. (2014). **Introdução a Robótica**. 1. ed. São Paulo: Unesp.
- Mitchell, T. (1997). **Machine Learning**. 1. ed. New York: McGraw Hill.
- Nicola, V.; Laurotto, M. e Delgado, K. (2020). **Avaliação Empírica de Classificadores e Métodos de Balanceamento para Detecção de Fraudes em Transações com Cartões de Créditos**. XVII Encontro Nacional de Inteligência Artificial e Computacional (ENIAC), Evento Online, p. 70-81.
- Oliveira, A.; Roesler, V.; Iochpe, C.; Schmidt, M.; Vigo, Á.; Barreto, S. e Duncan, B. (2017). **Comparison of Machine-Learning Algorithms to Build a Predictive Model for Detecting Undiagnosed Diabetes - ELSA-Brasil: Accuracy Study**. São Paulo Medical Journal, v. 135, n. 3, p. 234-246.
- Oliveira, D.; Assunção, W.; Souza, L.; Oizumi, W.; Garcia, A. e Fonseca, B. (2020). **Applying Machine Learning to Customized Smell Detection**. XXXIV Simpósio Brasileiro de Engenharia de Software (SBES), Natal, p. 233-242.
- Organização Mundial da Saúde (OMS)**. (1948). Constituição da Organização Mundial da Saúde. Genebra: OMS.
- Pressman, R. (2006). **Engenharia de Software**. 6. ed. São Paulo: Mcgraw-Hill Interamericana.
- Rodas, C.; Barros, S.; Souza, R. e Vidotti, S. (2022). **Análise de Sentimentos Sobre as Vacinas Contra Covid-19: Um Estudo com Algoritmo de Machine Learning em Postagens no Twitter**. RESDITE: Revista de Saúde Digital e Tecnologias Educacionais, v. 7, n. 3, p. 24-44.
- Ramchoun, H.; Ganou, Y.; Ettaouil, M. e Idrissi, M. (2016). **Multilayer Perceptron: Architecture Optimization and Training**. Revista Internacional de Multimídia Interativa e Inteligência Artificial, v.4, n. 1, p. 26-30.
- Rego, R. e Nunes, R. (2019). **Filtro de Bloom como Ferramenta de Apoio a Detectores de Ataques Web Baseados em Aprendizagem de Máquina**. XIX Simpósio Brasileiro de Segurança da Informação e de Sistemas Computacionais (SBSeg), São Paulo, p. 85-98.
- Rubí, J.; Carvalho, P. e Gondim, P. (2023). **Application of Machine Learning Models in the Behavioral Study of Forest Fires in the Brazilian Federal District Region**. Engineering Applications of Artificial Intelligence, v. 118, n. 10, p. 105649.
- Roveda, U. (2023). **Ciência Da Computação: O Que é, Grade Curricular e Como Aprender**. Disponível em: <https://kenzie.com.br/blog/ciencia-computacao/>. Acesso em: 11 nov. 2023.
- Santos, M.; Júnior, J.; Wada, D.; Tenório, A.; Nogueira-Barbosa, M. e Marques, P. (2019). **Artificial Intelligence, Machine Learning, Computer-Aided Diagnosis, and Radiomics: Advances in Imaging Towards to Precision Medicine**. Radiologia Brasileira, v. 52, n. 6, p. 387-396.
- Sartin, M.; Silva, A.; Kappes, C. e Filho, T. (2020). **Classifying the Macronutrient Deficiency in Soybean Leaf with Deep Learning**. XVII Encontro Nacional de Inteligência Artificial e Computacional (ENIAC), Evento Online, p. 638-649.

Szczepanski, M. (2019). **Economic Impacts of Artificial Intelligence (AI)**. Disponível em: [http://www.europarl.europa.eu/RegData/etudes/BRIE/2019/637967/EPRS_BRI\(2019\)637967_EN.pdf](http://www.europarl.europa.eu/RegData/etudes/BRIE/2019/637967/EPRS_BRI(2019)637967_EN.pdf). Acesso em: 13 nov. 2023.

Turing, A. (1950). **Computing Machinery and Intelligence**. Mind, v. 59, n.236, p.433-460.

APÊNDICE A

Tabela A1 - Publicações selecionadas após o 2º filtro

| ID | Título | Autores | Ano | Local de Publicação |
|-----|---|---|------|---------------------|
| P01 | Classification of Irregularity Communications in Public Ombudsmen Using Supervised Learning Algorithms | Cordeiro, F; Rabelo, R e Moura, R. | 2022 | ENIAC |
| P02 | Investigating Lexical NP-Chunking with Universal Dependencies for Portuguese | Souza, A e Ruiz, E. | 2022 | ENIAC |
| P03 | Previsão da duração de carregamentos de embarcações PLSV | Rachel Martins Ventriglia, Leonardo Bastos, Karla Figueiredo, Marley Vellasco | 2022 | ENIAC |
| P04 | Machine Learning Algorithms for Remaining Useful Life Prediction of Rolling Bearings | Zumpichiatti, D e Gomide, J. | 2022 | ENIAC |
| P05 | Cross-Domain Sentiment Analysis in Portuguese using BERT | Britto,L; Pessoa, L e Agostinho, S. | 2022 | ENIAC |
| P06 | Automatic Classification of Bug Reports for Mobile Devices: An Industrial Case Study | Lins, R; Barros, F; Prudêncio, R e Melo, W. | 2022 | ENIAC |
| P07 | Application of Deep Learning Models for Aircraft Maintenance | Sano, H e Berton, L. | 2022 | ENIAC |
| P08 | Feature engineering vs. extraction: clustering Brazilian municipalities through spatial panel agricultural data via autoencoders | Silva, M; Matos, L; Santos, F; Dompieri, M e Moura, F. | 2022 | ENIAC |
| P09 | A Four-Step Cascade Methodology to Classify MCN Codes Using NLP Techniques | Pinheiro, P; Siqueira, L e Amarias, M. | 2022 | ENIAC |
| P10 | Bayesian Neural Models for Time-Series Prediction of CS28 Compressive Strength in Cement Manufacturing | Lira, T e Finger, M. | 2022 | ENIAC |
| P11 | Evaluating the Potential of Federated Learning for Maize Leaf Disease Prediction | Antico,T; Moreira, L e Moreira, R. | 2022 | ENIAC |
| P12 | A lightweight approach for predicting errors in chess matches | Comarela, G e Silva, D. | 2021 | ENIAC |
| P13 | Previsão de Taxa de Perfuração em Poços de Petróleo Offshore Utilizando Aprendizado de Máquina | Branco, A e Gomide, J. | 2021 | ENIAC |
| P14 | A Comparative Analysis of Machine Learning Named Entity Recognition Tools for the Brazilian and European Portuguese Language Variants | Pinheiro, B; Sousa, E; Vitório, D e Albuquerque. | 2021 | ENIAC |
| P15 | Deep Learning and Mel-spectrograms for Physica Violence Detection in Audio | Lacerda, T; Miranda, P; Câmara, A e Furtado, A | 2021 | ENIAC |
| P16 | Identification of Emotions in Spoken Language Using Deep Learning | Oliveira, E e Figueiredo, C. | 2021 | ENIAC |
| P17 | Analysis of a Brazilian Indigenous corpus using machine learning methods | Lima, T; Nascimento, A; Miranda, P e Mello, R. | 2021 | ENIAC |
| P18 | Offline Handwritten Signature Authentication with Conditional Deep Convolutional Generative Adversarial Networks | Yonekura, D e Guedes, E. | 2021 | ENIAC |

| | | | | |
|------------|--|---|------|-------|
| P19 | Applying machine learning to assist the diagnosis of COVID-19 from blood and urine exams | Jessica Almeida dos Santos, Lilian Berton | 2021 | ENIAC |
| P20 | A Machine Learning-based System for Financial Fraud Detection | Andrade, J; Paulucio, L; Paixão, T; Berriel, R; Carneiro, T; Carneiro, R; Souza, A; Badue, C e Santos, T. | 2021 | ENIAC |
| P21 | A Comparative Analysis of Countries' Performance According to SDG Indicators based on Machine Learning | Souza, G; Santos, J; SantClair, G; Gomide, J e Santos L. | 2021 | ENIAC |
| P22 | Classification of chest X-ray images using Machine Learning and Histogram of Oriented Gradients | Fellipe M. C. Barbosa, Anne Magaly de P. Canuto | 2021 | ENIAC |
| P23 | Comparison of GANs for Covid-19 X-ray classification | Luiz Felipe Cavalcanti, Lilian Berton | 2021 | ENIAC |
| P24 | Impact of Feature Selection on Clustering Images of Vertebral Compression Fractures | Candido, R; Lama, R; Chiari, N; Nogueira-Barbosa, M; Marques, P e Tinós, R. | 2020 | ENIAC |
| P25 | Sensor Validation for Indoor Air Quality using Machine Learning | Seibert, V; Araújo, R e McElligott, R. | 2020 | ENIAC |
| P26 | Medicinal Plant Recognition Using Color, Texture and Shape Feature | Britto, L; Pacifico, L; Silva, M e Ludermit, T. | 2020 | ENIAC |
| P27 | Classifying the Macronutrient Deficiency in Soybean Leaf with Deep Learning | Sartin, M; Silva, A; Kappes, C e Filho, T. | 2020 | ENIAC |
| P28 | Knowledge Discovery in Brazilian Soccer Championship Scout Data | Ortolan, L e Silva, D. | 2020 | ENIAC |
| P29 | Aprendizado Profundo Aplicado na Previsão de Receita Tributária Utilizando Variáveis Endógenas | Silva, P e Figueiredo, K. | 2020 | ENIAC |
| P30 | Classification of Court Lawsuits Pages using Multimodal Convolution Neural Networks | Mota, C; Lima, A; Nascimento, A; Miranda, P e Mello, R. | 2020 | ENIAC |
| P31 | Stock Trading Classifier with Multichannel Convolutional Neural Network | Nascimento, D; Costa, A e Bianchi, R. | 2020 | ENIAC |
| P32 | Hybrid Approach for Detecting Brazilian Real Coins with Localization Algorithms and Convolutional Neural Networks | Yonekura, D e Guedes, E. | 2020 | ENIAC |
| P33 | Avaliação Empírica de Classificadores e Métodos de Balanceamento para Detecção de Fraudes em Transações com Cartões de Crédito | Nicola, V; Lauretto, M e Delgado, K. | 2020 | ENIAC |
| P34 | Cloud Computing and Machine Learning for Analysis of Large Volumes of Educational Data | Neto, F (Francisco Q. S. Neto); Silva, R; Gouveia, R. Batista, M e Oliveira, I. | 2020 | ENIAC |
| P35 | Using Artificial Neural Networks to Classify Treadmill Running Patterns in High-Performance Sports | Baldo Junior, S; Tinós, R e Santiago, P. | 2020 | ENIAC |
| P36 | Hate Speech Detection in Portuguese with Naïve Bayes, SVM, MLP and Logistic Regression | Silva, A e Roman, N. | 2020 | ENIAC |
| P37 | Automatic Identification of Postings Related to the Use Through Deep Learning Models | Oliveira, H; Arruda, A e Mendes, M. | 2019 | ENIAC |
| P38 | An acoustic scene classification approach involving domestic violence using machine learning | Souto, H; Mello, R e Furtado, A. | 2019 | ENIAC |

| | | | | |
|------------|---|---|------|-------|
| P39 | Classifying Readers with Dyslexia from Eye Movements using Machine Learning and Wavelets | Ceravolo, I; Brasil, A e Karin S. Komati | 2019 | ENIAC |
| P40 | Plant Species Classification Using Extreme Learning Machine | Britto, L e Pacifico, L. | 2019 | ENIAC |
| P41 | Human Values Classification in Social Network Using Machine Learning | Correia, S; Malheiros, Y; Nascimento, A e Gouveia, V. | 2019 | ENIAC |
| P42 | Supervised Methods Applied to the Construction of a Vision System for the Classification of Cocoa Beans in the Cut-Test | Santos, F; Canuto, A; Bedregal, B; Palmeira, E e Silva, I | 2019 | ENIAC |
| P43 | Forecasting of Espírito Santo State ICMS Revenue through Cascading Feature Selection and Machine Learning Techniques | Carmo, M; Boldt, A e Komati, K. | 2019 | ENIAC |
| P44 | Detecting Suicidal Ideation on Tweets | Cardoso, V; Silva, A; Sinoara, R; Rezende, S e Calçada, D. | 2019 | ENIAC |
| P45 | Single and Multiple Failures Diagnostics of Pneumatic Valves using Machine Learning | Sano, H; Malere, J e Berton, L. | 2019 | ENIAC |
| P46 | On the Analysis of Machine Learning Classifiers to Detect Traffic Congestion in Vehicular Networks | Carvalho, L; Silva, M; Santos, E e Guidoni, D. | 2019 | ENIAC |
| P47 | Image classification of Kuzushiji ideograms with Convolutional Neural Networks | Martins, L; Muramatsu Junior, M e Serapião, A. | 2019 | ENIAC |
| P48 | Prediction of musical genres using machine learning techniques | Dim, C; Alves, L e Sousa, P. | 2019 | ENIAC |
| P49 | Housing Prices Prediction with a Deep Learning and Random Forest Ensemble | Afonso, B; Melo, L; Oliveira, W; Sousa, S e Berton | 2019 | ENIAC |
| P50 | Deep Learning in Risk Assessment | Fernandes, J; Bisaro, L; Santos, F e Carneiro, M. | 2019 | ENIAC |
| P51 | Employing Gradient Boosting and Anomaly Detection for Prediction of Frauds in Energy Consumption | Albiero, B; Uyrá, E; Vilarino, R; Silva, J; Souza, T; Santos, R; Yamouni, S e Vicente, R. | 2019 | ENIAC |
| P52 | A Text Analysis Approach for Cooking Recipe Classification Based on Brazilian Portuguese Documents | Britto, L; Oliveira, E; Pacifico, L e Ludermit, T. | 2019 | ENIAC |
| P53 | Deep Learning for Automatic Image Captioning | Scoparo, M e Serapiao, A. | 2019 | ENIAC |
| P54 | Comparison of Machine Learning Models for Total Dengue Cases Prediction | Carvalho, T; Tenorio, G; Figueiredo, K; Vellasco, M e Caarls, W | 2019 | ENIAC |
| P55 | Recognizing Power-law Graphs by Machine Learning Algorithms using a Reduced Set of Structural Features | Lima, A; Vignatti, A e Silva, M. | 2019 | ENIAC |
| P56 | Anode Temperature Classification of Liquid Metal in an Electric Arc Furnace using K-Nearest Neighbors | Ferreira, T; Figueiredo, K e Vellasco, M. | 2019 | ENIAC |
| P57 | Automatic Identification of Equivalence of Concepts in Different Languages for Never-Ending Learning | Marino, S e Hruschka Junior E. | 2018 | ENIAC |
| P58 | Applying Recurrent Neural Networks with Long Short-Term Memory in Clustered Stocks | Affonso, F e Dias, T. | 2018 | ENIAC |

| | | | | |
|------------|--|---|------|-------|
| P59 | Computer-Aided Tuberculosis Detection from Chest X-Ray Images with Convolutional Neural Networks | Evangelista, L e Guedes, E. | 2018 | ENIAC |
| P60 | A Grammar-based Genetic Programming Approach to Optimize Convolutional Neural Network Architectures | Diniz, J; Cordeiro, F; Miranda, P e Silva, L. | 2018 | ENIAC |
| P61 | Characterization and identification of twelve-tone composers | Lucas F. P. Costa, Andres E. Coca S | 2018 | ENIAC |
| P62 | A Machine Learning Approach Based on Automotive Engine Data Clustering for Driver Usage Profiling Classification | Barreto, C; Xaver-Junior, J; Canuto, A e Silva, I. | 2018 | ENIAC |
| P63 | Daily streamflow forecasting for Paraíba do Sul river using machine learning methods with hydrologic inputs | Gorodetskaya, Y; Fonseca, L; Tavares, G e Ribeiro c. | 2018 | ENIAC |
| P64 | Evaluation of Deep Learning Architectures Applied to Identification of Diseases in Grape Leaves | Oliveira, F; Farias, F e Caldas, B. Bernado João | 2018 | ENIAC |
| P65 | Evaluating the Impact of Pre-clustering and Class Imbalance on Solar Flare Forecasting | Bueno, M; Coelho, G; Silva, A e Gradvoh, A. | 2018 | ENIAC |
| P66 | Facial Expressions Classification with Ensembles of Convolutional Neural Networks and Smart Voting | Moraes, R; Guedes, E e Figueiredo, C. (Carlos Mauricio) | 2018 | ENIAC |
| P67 | Food Recognition System for Nutrition Monitoring | Freitas, C; Cordeiro, F e Silva, A. | 2018 | ENIAC |
| P68 | NELL's subcategories from a question answering environment | Souza, W; Brognara, D; Leite, J e Hruschka Jr, E. | 2018 | ENIAC |
| P69 | Forecasting economic time series using chaotic neural networks | Victor, H; Gonçalves e Rosa, J. | 2018 | ENIAC |
| P70 | Plant Classification Using Weighted k-NN Variantsod Recognition System for Nutrition Monitoring | Britto, L e Pacifico, L. | 2018 | ENIAC |
| P71 | Product Recommendation Using Classification Algorithms | Dalton, V; Granatyr, J; Knop, J e Almeida, C | 2018 | ENIAC |
| P72 | Performance Analysis of Deep Neural Networks in piRNAs Classification | Costa, A; Santos, R e Cerri, R. | 2018 | ENIAC |
| P73 | Um modelo para seleção automática de algoritmos de extração de eventos de trânsito para aplicações ITS | Pereira, A; Silva, T; Silva, F; Correia, L e Loureiro, A. | 2021 | SBCUP |
| P74 | Modelo de Detecção de Fraudes elétricas Baseado em Aprendizado de Máquina | Pfeiff, G; Araújo, F; Oliveira, H; Rosário, D e Cerqueira, E. | 2020 | SBCUP |
| P75 | Arquitetura Embarcável para Detecção de Eventos Sonoros Utilizando Inteligência Artificial | Filho, L e Figueiredo, C. (Carlos Mauricio e Luiz Carlos) | 2020 | SBCUP |
| P76 | Análise de Históricos de Contextos para Classificação do Estresse Mental em Situações Reais por meio da Variabilidade da Frequência Cardíaca | Bavaresco, R e Barbosa, J. | 2019 | SBCUP |
| P77 | Atualização de Modelo baseado em Aumento de Dados e Transferência de Aprendizagem para Detecção de Intrusão em Redes | Horchulhack, P; Viegas, E; Santin, A e Geremias, J. | 2022 | SBSEG |
| P78 | Detecção incremental de comportamento malicioso em VANETs | Dutra, F; Bonfim, K; Travagini, C; Meneguette, R; Santos, A e Pereira | 2022 | SBSEG |

| | | | | |
|------------|---|--|------|-------|
| P79 | Avaliação da Capacidade de Generalização de IDS Stateful Utilizando Aprendizado de Máquina | Domingues, M; Bertoli, G; Melo, L; Saotome, O; Santos, A e Pereira, L. | 2022 | SBSEG |
| P80 | Autenticação Contínua Usando Sensores Inerciais dos Smartphones e Aprendizagem Profunda | Paz, I; Bragança, H e Souto. | 2022 | SBSEG |
| P81 | Multiclass Decomposition and Artificial Neural Networks for Intrusion Detection and Identification in Internet of Things Environments | Souza, C; Cardoso, J.V e Westphall, C. | 2021 | SBSEG |
| P82 | Métodos de Aprendizado de Máquina Adversariais na Detecção de Anomalias em Redes de Computadores | Camargo, L; Reis, C; Paiola, P; Papa, J; Brega, J e Costa, K. | 2021 | SBSEG |
| P83 | Detecção de Ataques a Redes IoT Usando Técnicas de Aprendizado de Máquina e Aprendizado Profundo | Bochie, K; Gonzalez, E; Giserman, L; Campista, M e Costa, L. | 2020 | SBSEG |
| P84 | Abordagem Fim-a-Fim para Uso de Aprendizado de Máquina em IDS – Caso de Detecção Stateless para TCP Scan | Bertoli, G; Pereira, L; Verri, F; Marcondes, C; Santos, A e Saotome, O. | 2020 | SBSEG |
| P85 | A Machine Learning Approach to Detect Misuse of Cryptographic APIs in Source Code | Rodrigues, G; Braga, A e Dahab, R. | 2020 | SBSEG |
| P86 | Filtro de Bloom como Ferramenta de Apoio a Detectores de Ataques Web baseados em Aprendizagem de Máquina | Rego, Richard e Nunes, R. | 2019 | SBSEG |
| P87 | A Forensic Nudity Detector Based on Machine Learning | Moreira, D e Fechine, J. | 2018 | SBSEG |
| P88 | Algoritmos de Aprendizado de Máquina Aplicados ao Reconhecimento de Usuário Baseado na Dinâmica da Digitação: Um Estudo Comparativo | Cruz, M e Goldschmidt, R. | 2018 | SBSEG |
| P89 | Integração de Sistemas para Predição de Deslizamentos de Terra Baseada em Aprendizado de Máquina | Pedreira, L; São Mateus, M e Calumby, R. | 2022 | SBSI |
| P90 | On Using Artificial Intelligence in the Search of the Best Professional Resumes | Charcon, D; Omar, N e Monteiro, L.H. (Luiz Henrique Alves Monteiro) | 2022 | SBSI |
| P91 | Identifying Xenophobia in Twitter Posts Using Support Vector Machine with TF/IDF Strategy | Santos, A; Rodrigues, A e Melo, H. | 2022 | SBSI |
| P92 | Public Administration Suppliers Classification Model Based on Supervised Machine Learning | Sousa Junior, J; Machado, V; Veras, R; Santos, R; Lima, B; Silva, A; Sousa, F.A (Francisco Alysson), Filho, F. | 2022 | SBSI |
| P93 | Predicting IMDb Rating of TV Series with Deep Learning: The Case of Arrow | Gomes, A.L (Ana Luiza); Vianna Jr, G; Escovedo, T e Kalinowski, M. | 2022 | SBSI |
| P94 | Automated Statistics Extraction of Public Security Events Reported Through Microtexts on Social Networks | Ferreira, F; Duarte, J e Ugulino, W. | 2022 | SBSI |
| P95 | Inferência Automática de Nível Calórico de Receitas Culinárias Através de Técnicas de Aprendizagem de Máquina | Britto, L; Pacífico, L e Ludermit, T. | 2021 | SBSI |
| P96 | Machine Learning Applied to the INSS Benefit Request | Barchilon, N e Escovedo, T. | 2021 | SBSI |

| | | | | |
|-------------|---|---|------|------|
| P97 | Social bots detection in Brazilian presidential elections using natural language processing | Ferreira, G; Santos, B; Do Ó, M; Braz, R e Digiampietri, L. | 2021 | SBSI |
| P98 | Um método baseado em aprendizado de máquina para previsão da produção de refeições em restaurantes universitários | Santos, Y; Saqui, D e Dos Santos, P, | 2021 | SBSI |
| P99 | A Model to Patient Abandonment Prediction in the Pulmonary Rehabilitation | Heckler, W; Carvalho, J; Costa, C e Barbosa, J. | 2020 | SBSI |
| P100 | An Intelligent System to Enhance the Productivity and Sustainability in Soybean Crop Enterprises | Pereira, D; Bugatti, P; Lopes, F; Souza, A e Saito, P. | 2019 | SBSI |
| P101 | Fraud Detection in Social Commerce: Combining Structured Attributes and Images | Batista, A; Figueiredo, K e Goldschmidt, R. | 2019 | SBSI |
| P102 | Attribute Selection Based on Genetic and Classification Algorithms in the Prediction of Hospitalization Need of COVID-19 Patients | Colpo, M; Alves, B; Pereira, K; Brandão, A; Aguiar, M e Primo, T. | 2019 | SBSI |
| P103 | Application of Clustering Algorithms for Discovering Bug Patterns in JavaScript Software | Macedo, C; Ruela, A e Delgado, K. | 2019 | SBSI |
| P104 | A Deep Learning Approach to the Malware Classification Problem Using Autoencoders | Pinto, D; Duarte, J e Sant'Ana, R. | 2019 | SBSI |
| P105 | O Uso da Rede Neural Convolutacional como Classificador de Emoções em um Sistema de Recomendação de Música | Lopes, P; Lasmar, E; Rosa, R e Rodríguez. | 2018 | SBSI |
| P106 | Uma Análise Comparativa de Algoritmos de Classificação de Pedidos em uma Plataforma de Empréstimos Peer-to-Peer | Rodrigues, D; Brasil, A; Costa, M; Komati, K e Pinto, L. | 2018 | SBSI |
| P107 | Machine Learning for Change-Prone Class Prediction: A History-Based Approach | Silva, R; Farah, P.R(Paulo Roberto) e Vergilio, S. | 2022 | SBES |
| P108 | Understanding Thresholds of Software Features for Defect Prediction | Santos, G; Veloso, A e Figueiredo, E. | 2022 | SBES |
| P109 | HealthyEnv: A Tool to Assist in Health Assessment of Software Repositories | Winter, D; Avelino, G e Miranda, C. | 2022 | SBES |
| P110 | Deep Reinforcement Learning based Android Application GUI Testing | Collins, E; Dias Neto, A; Vincenzi, A e Maldonado, J. | 2021 | SBES |
| P111 | Smart prediction for refactorings in the software test code | Martins, L; Costa, H; Bezerra, C e Machado, I | 2021 | SBES |
| P112 | Applying Machine Learning to Customized Smell Detection: A Multi-Project Study | Oliveira, D; Assunção, W; Souza, L; Oizumi, Garcia, A e Fonseca B. | 2020 | SBES |
| P113 | InSet: A Tool to Identify Architecture Smells Using Machine Learning | Cunha; W; Armijo, G e Camargo, V. | 2020 | SBES |
| P114 | Understanding and Detecting Harmful Code | Lima, R; Souza, J; Fonseca, B; Teixeira, L; Gheyi, L; Ribeiro, M; Garcia, A e Mello, R. | 2020 | SBES |
| P115 | Software Engineering Repositories: Expanding the PROMISE Database | Lima, M; Valle, V; Costa, E, Lira, F e Gadelha, B. | 2019 | SBES |
| P116 | EmbSE: A Word Embeddings Model Oriented Towards Software Engineering Domain | Fávero, E; Casanova, D e Pimental, A (Andrey Ricardo) | 2019 | SBES |

| | | | | |
|-------------|---|---|------|----------|
| P117 | A DRL Approach for Object Transportation in Complex Environments | Silva, A; Rezeck, P; Luz, G; Alves, T; Macharet, D e Chaimowicz, L. | 2022 | SBR/LARS |
| P118 | Active Perception Applied To Unmanned Aerial Vehicles Through Deep Reinforcement Learning | G. Mateus,M; Grando, R e Drews-Jr, P. | 2022 | SBR/LARS |
| P119 | AGV Detection in Industrial Environments through Computer Vision | Barioni, W; Latini, I; Lazzaretti, A; Teixeira, M; Neves, F e Arruda, L. | 2022 | SBR/LARS |
| P120 | Application of Reinforcement Learning to the Orientation and Position Control of a 6 Degrees of Freedom Robotic Manipulator | Campos, F; Fidêncio, A; Domingues, J; Pessin, G e Freitas, G. | 2022 | SBR/LARS |
| P121 | DA-SLAM: Deep Active SLAM based on Deep Reinforcement Learning | Alcade, M; Ferreira, M; González, P; Andrade, F e Tejera, G. | 2022 | SBR/LARS |
| P122 | Deep Neural Network Algorithm to Control a Curved Kicking Mechanism in RoboCup Small Size League | Azevedo, F; Leão, G e Maximo, M. | 2022 | SBR/LARS |
| P123 | Detecting Data Injection Attacks in ROS Systems using Machine Learning | Antunes, R; Dalmazo, B e Drews, P. | 2022 | SBR/LARS |
| P124 | Addressing Lane Keeping and Intersections using Deep Conditional Reinforcement Learning | Silva, V e Grassi, V. | 2021 | SBR/LARS |
| P125 | CBNAV: Costmap Based Approach to Deep Reinforcement Learning Mobile Robot Navigation | Tomasi, D e Todt, E. | 2021 | SBR/LARS |
| P126 | Detection of invasive vegetation through UAV and Deep Learning | Charles, C; Kim, P; Almeida, A; Nascimento, E; Rocha, L e Vivaldini, K. | 2021 | SBR/LARS |
| P127 | Deep Reinforcement Learning Applied to IEEE Very Small Size Soccer Strategy | Medeiros, T; Máximo, M e Yoneyama, T. | 2020 | SBR/LARS |
| P128 | Deep Reinforcement Learning for Visual Semantic Navigation with Memory | Santos, I e Romero, R. | 2020 | SBR/LARS |
| P129 | Deep Reinforcement Learning for Mapless Navigation of Unmanned Aerial Vehicles | Grando, R; Jesus, J e Drews-Jr, P. | 2020 | SBR/LARS |
| P130 | System for Recognition of Facial Expressions Using Machine Learning | Silva, T; Andrade, A e Silva, N. | 2020 | SBR/LARS |
| P131 | Facial Recognition Experiments on a Robotic System Using One-Shot Learning | Belo, J; Sanches, F e Romero, R. | 2019 | SBR/LARS |
| P132 | Remote Control for Mobile Robots Using Gestures Captured by the RGB Camera and Recognized by Deep Learning Techniques | Martinelli, D; Sousa, A; Augusto, M; Kalempa, V; Oliveira, A; Rohrich, R e Teixeira, M. | 2019 | SBR/LARS |
| P133 | A Machine Learning-Based Approach to Calibrate Low-Cost Particulate Matter Sensors | Pastório, A; Spanhol, F; Martins, L e Camargo, E. | 2022 | SBESC |
| P134 | Assessment and Optimization of 1D CNN Model for Human Activity Recognition | Reusch, R;Juracy, L e Moraes, F. | 2022 | SBESC |
| P135 | Comparison of Different Adaptable Cache Bypassing Approaches | Carmin, M; Ensina, L e Alvez, M. | 2022 | SBESC |

| | | | | |
|-------------|--|---|------|-------|
| P136 | Data-driven Anomaly Detection of Engine Knock based on Automotive ECU | Francis, L; Pierozan, V; Gracioli, G e Araujo, G. | 2022 | SBESC |
| P137 | Distributed Learning using Consensus on Edge AI | Fidelis, S; Castro, M e Siqueira, F. | 2022 | SBESC |
| P138 | Deep-Learning-Based Embedded ADAS System | Sousa, F; Silva, M; Santos, R; Silva, M e Oliveira, R. | 2021 | SBESC |
| P139 | Machine Learning for Identification and Classification of Crops and Weeds | Armstrong, D; Götz, M; Nardelli, V e Gomes, V. | 2021 | SBESC |
| P140 | Performance Analysis of Machine Learning-Based Systems for Detecting Deforestation | Araújo, M; Andrade, E e Machida, F. | 2021 | SBESC |
| P141 | Data Confidence Applied to Wind Turbine Power Curves | Scheffel, R; Hoffman, J; Horstmann, L; Araujo, G; Fröhlich, A; Matsuo, T; Pohlenz, V e Nishioka, M. | 2020 | SBESC |
| P142 | Brazilian Mercosur License Plate Detection: a Deep Learning Approach Relying on Synthetic Imagery | Ribeiro, V; Great, V; Bezerra, A; Silvano, G; Silva, I; Endo, P e Lynn, T. | 2019 | SBESC |
| P143 | A Deep Learning approach for Energy Disaggregation considering Embedded Devices | Santos, E; Freitas, C e Aquino, A. | 2019 | SBESC |
| P144 | Deep Learning applied to the Identification of Fruit Fly in Intelligent Traps | Martins, V; Freitas, L; Brisolara, L; Aguiar, M e Ferreira Jr, P. | 2019 | SBESC |
| P145 | An Embedded Application to Identify Degradation in Energized Polymeric Insulators Using Machine Learning and Wavelet Transform | Cunha, R; Silva Junior e Medeiros, C. | 2018 | SBESC |
| P146 | An Embedded Automatic License Plate Recognition System using Deep Learning | Izidio, D; Ferreira, A e Barros, E. | 2018 | SBESC |
| P147 | Applying Non-Destructive Testing and Machine Learning to Ceramic Tile Quality Control | Cunha, R; Maciel, R; Nandi, G; Daros, M; Cardoso, J; Francis, L; Ramos, V, Marcelino, R; Fröhlich, A e Araujo, G. | 2018 | SBESC |

Fonte: Os Autores (2023)

As Tabelas de A2 a A12 são as aplicações referentes as 11 áreas que não foram discutidas na QP2. Cada aplicação está descrita e identificada com o ID da sua publicação.

Tabela A2 - Aplicação da Área De Ciências Sociais e Humanas

- Investigar dependências universais e como podem ser usadas para identificar e extrair sintagma nominal lexical relacionados com um bom grau de precisão [P02]
- Classificação de línguas indígenas com ajuda de aprendizado de máquina, para assim ajudar na documentação dessas línguas, bem como no estudo de semelhanças entre dialetos [P17]
- Identificação de discurso de ódio em tweets em português buscando limitar o impacto negativo na sociedade [P36]
- Classificação de valores humanos com base nas mensagens do Twitter podendo influenciar positivamente estratégias de negócios, políticas públicas e iniciativas sociais [P41]
- Classificação de tweets para identificar pensamentos suicidas buscando a prevenção precoce para possíveis acidentes [P44]
- Classificação de ideogramas Kuzushiji em estilo cursivo proporcionando a possível compreensão de documentos históricos escritos nessa forma de escrita [P47]
- Classificação de idiomas ajudando na adaptação de sistemas e aplicativos para atender a usuários em diferentes regiões do mundo [P57]

- Criação de um modelo para classificação de textos xenófobos no contexto brasileiro possibilitando o tratamento adequado da proliferação de discurso de ódio [P91]
- Detecção de Bots na rede social Twitter durante as eleições buscando diminuir a desinformação [P97]

Fonte: Os Autores (2023)

Tabela A3 - Aplicação da Área de Economia

- Classificação de NCM nos produtos dos países do Mercosul para suas identificações corretas em notas fiscais [P09]
- Classificação de sinais de negociação no mercado de ações usando técnicas de Machine Learning [P31]
- Detecção e classificação de moedas brasileiras através de imagens com utilização em dispositivos de pagamento, contagem financeira e auxílio a pessoas com limitações visuais [P32]
- Predição de preços de imóveis no mercado imobiliário [P49]
- Avaliação de risco de crédito no mercado imobiliário para melhorar esse processo dentro de instituições financeiras, possibilitando que elas consigam oferecer melhores produtos e serviços [P50]
- Previsão do mercado de ações usando Machine Learning [P58]
- Prever séries temporais econômicas utilizando algoritmos para facilitar esse processo [P69]
- Aplicação capaz de identificar os candidatos que detêm as melhores características, conforme a vaga oferecida para melhorar a eficiência da equipe do RH ao selecionar funcionários [P90]
- Classificação de pedidos de empréstimos para prever inadimplência em uma plataforma P2P [P106]

Fonte: Os Autores (2023)

Tabela A4 - Aplicação da Área de Mídia e Entretenimento

- Previsão de erros em partidas de xadrez online [P12]
- Identificação automática de Postagens Relacionadas ao Uso (PRU) em redes sociais utilizando algoritmos de Machine Learning [P37]
- Classificação automática de gêneros musicais usando técnicas de Machine Learning [P48]
- Realizar a classificação automática de receitas culinárias em português brasileiro para sistemas de recomendação [P52]
- Classificar obras dodecafônicas por compositores usando características extraídas da série original [P61]
- Realizar a previsão da classificação de uma série no IMDb para que assim a escolha de renovação ou início de um novo programa seja mais fácil [P93]
- Classificação de Emoções em Textos de Redes Sociais para Aprimoramento de um Sistema de Recomendação de Música [P105]

Fonte: Os Autores (2023)

Tabela A5 - Aplicação da Área Industrial

- Previsão da duração dos carregamentos dos navios PLSVs, que é o recurso responsável pela interligação de poços submarinos à unidade estacionária de produção, sendo crítico para a exploração de offshore de petróleo [P03]
- Realizar a previsão do tempo de vida útil restante de equipamentos mecânicos a partir de dados de vibração de testes realizados até a falha [P04]
- Previsões robustas de resistência à compressão do cimento [P10]
- Previsão da taxa de perfuração (ROP) durante a perfuração de poços de petróleo offshore de pré-sal da Bacia de Santos. [P13]
- Classificação da temperatura do ânodo em fornos elétricos a arco utilizando algoritmos de Machine Learning [P56]
- Detecção de falhas para evitar a detonação de um motor no âmbito da indústria automotiva [P136]
- Emissão acústica utilizando Machine Learning para testar produtos e detectar falhas estruturais [P147]

Fonte: Os Autores (2023)

Tabela A6 - Aplicação da Área de Direito e Justiça

- Classificação dos comunicados de irregularidades recebidos por meio da ouvidoria do TCE [P01]
- Identificar cenas de violência física convertendo áudios em imagens [P15]
- Classificação de empresas suscetível a fraudes a partir da detecção de sonegação fiscal [P20]
- Classificação automatizada de páginas em processos judiciais, onde cada página deve ser classificada com base em seu conteúdo [P30]
- Comparativo em modelos de classificação de transações fraudulentas em cartões de crédito no âmbito do comércio eletrônico, levando em consideração como o balanceamento de dados afeta esse processo [P33]
- Classificação de cenas acústicas para detectar violência doméstica usando técnicas de Aprendizado de Máquina [P38]
- Previsão de fraudes e detecção de anomalias em consumo de energia elétrica. O objetivo foi identificar padrões anômalos no consumo e selecionar quais consumidores irão para a verificação [P51]
- Detecção de fraudes no consumo elétrico para evitar prejuízo financeiro para as empresas de energia elétrica. [P74]

Fonte: Os Autores (2023)

Tabela A7 – Aplicação da Área de Mobilidade Urbana

- Detecção de níveis de congestionamento em estradas para assim fornecer rotas alternativas com o objetivo de evitar congestionamentos usando algoritmos classificadores de aprendizado de máquina [P46]
- Classificar e agrupar os perfis de motoristas para a criação de uma plataforma online [P62]
- Detecção de eventos de trânsito com informações: tipo, local e momento que ocorreu. Foi utilizado dados de duas redes sociais para essa extração. O modelo busca oferecer uma opção para melhorar sistemas de transporte inteligentes (ITS) [P73]
- Detecção de conteúdos falsos em Mensagens de Segurança Básica (BSMs), as quais contêm dados relevantes sobre o tráfego. [P78]
- Aplicativo que verifica cenários básicos de tráfego no trânsito, segmenta as faixas da estrada e classifica se o veículo está se desviando da estrada. Detecta objetos no cenário de trânsito e classifica as placas de trânsito para inferir o limite de velocidade da via. [P138]
- Reconhecimento de placas de veículos para melhorar o tráfego e segurança nas cidades [P146]

Fonte: Os Autores (2023)

Tabela A8 – Aplicação da Área de Gestão Pública

- Previsão mensal do ICMS do Estado do Rio de Janeiro pois uma previsão mais aperfeiçoada, aumenta a qualidade do planejamento do orçamentário anual [P29]
- Previsão da arrecadação do Imposto sobre Circulação de Mercadorias e Serviços (ICMS) no Espírito Santo [P43]
- Seleção de processos a serem auditados pelo Tribunal de Contas do Estado de Piauí (TCE-PI) [P92]
- Construção de um modelo que consiga prever se determinado novo pedido de benefício do INSS será concedido ou indeferido analisando os dados fornecidos do cidadão [P96]
- Previsão quantitativa de alimentos para evitar desperdício de comida em restaurantes universitários [P98]

Fonte: Os Autores (2023)

Tabela A9 – Aplicação da Área de Ciências Naturais

- Comparação de Técnicas na Previsão de vazão média diária do rio Paraíba do Sul [P63]
- Utilizando método de classificação para previsão de explosões solares, devido ao seu impacto na Terra [P65]
- Classificação de piRNAs (Formam o maior grupo de sequências de ncRNA (RNA não codificante)) [P72]
- Realizar a previsão de deslizamentos de terra induzidos por chuvas a partir de registros desses acontecimentos no inventário de deslizamentos [P89]
- O monitoramento populacional de duas espécies de moscas-das-frutas para controle de pragas [P144]

Fonte: Os Autores (2023)

Tabela A10 – Aplicação da Área do Meio Ambiente

- Comparar países segundo o seu desempenho no Desenvolvimento Sustentável (ODS) [P21]
- Calibração de Sensores em estações de referência de qualidade de ar [P133]
- Sistemas de Comparação em análise de imagem para monitorar o desmatamento na floresta amazônica [P140]

Fonte: Os Autores (2023)

Tabela A11 – Aplicação da Área de Engenharia Elétrica

- Monitoramento de carga não intrusivos em residência [P143]
- Classificador embarcado para identificação de degradação em isoladores poliméricos energizados utilizando uma plataforma micro controladora de 32 bits [145]

Fonte: Os Autores (2023)

Tabela A12 – Aplicação da Área da Aeronáutica

- Classificação de Válvulas de Corte Reguladas por Pressão (PRSOV) para Manutenção nas Aeronaves [P07]
- Diagnóstico de falhas em válvulas pneumáticas em sistemas aeronáuticos usando aprendizado de máquina [P45]

Fonte: Os Autores (2023)